

Early Warning Risiko Ketidakberhasilan Mahasiswa dalam Mata Kuliah pada Minggu Keempat Menggunakan Supervised Learning dan Knowledge-Based Risk Layer pada Open University Learning Analytics Dataset

Muhammad Rizky Hajar
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
riskihajar@students.amikom.ac.id

Andi Sunyoto
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
andi@amikom.ac.id

Alwie Muflich
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
alwiemuflich@students.amikom.ac.id

Robert Marco
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
robert.marco@amikom.ac.id

Heri Santosa
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
heri.sant@students.amikom.ac.id

Abstract. Hasil akhir mata kuliah memberi informasi penting bagi monitoring akademik dan perencanaan intervensi dini. Penelitian ini mengembangkan early warning risiko ketidakberhasilan mahasiswa dalam mata kuliah pada akhir minggu keempat menggunakan Open University Learning Analytics Dataset (OULAD). Setiap baris merepresentasikan satu mahasiswa pada satu module-presentation. Target dirumuskan sebagai klasifikasi biner, yaitu *AtRisk* untuk hasil akhir mata kuliah *Withdrawn* dan *Fail*, serta *Successful* untuk *Pass* dan *Distinction*. Fitur prediktor dibentuk dari data demografis, registrasi awal, assessment, dan aktivitas Virtual Learning Environment yang tersedia sampai hari ke-28. Evaluasi membandingkan Logistic Regression, Random Forest, dan XGBoost melalui hold-out test berbasis kelompok mahasiswa dan 5-fold GroupKFold. Random Forest dipilih berdasarkan recall *AtRisk* cross-validation tertinggi sebesar 0,7107. Pada hold-out test, model tersebut menghasilkan accuracy 0,7594, precision 0,8007, recall 0,7213, F1-score 0,7589, dan ROC-AUC 0,8396. Knowledge-based risk layer menggabungkan prediksi model dengan empat indikator perilaku awal untuk menghasilkan level *High Risk*, *Medium Risk*, dan *Low Risk* beserta alasan dan rekomendasi intervensi. Sistem gabungan meningkatkan recall menjadi 0,7866 dengan precision 0,7043. Hasil analitik disajikan melalui dashboard statis yang memuat indikator risiko, prioritas module-presentation, sinyal dominan, dan daftar mahasiswa untuk mendukung monitoring akademik. Pendekatan ini menyediakan integrasi prediksi, interpretasi berbasis aturan, dan visual decision support untuk intervensi dini pada tingkat mata kuliah.

Keywords. academic risk prediction, course withdrawal, course failure, supervised learning, OULAD, early warning system

I. INTRODUCTION

Kegagalan dan pengunduran diri dari mata kuliah menjadi perhatian dalam pendidikan tinggi karena berkaitan dengan capaian belajar, kualitas layanan akademik, dan efektivitas pengambilan keputusan institusional. Penelitian sebelumnya menunjukkan bahwa machine learning dapat memprediksi retensi mahasiswa menggunakan karakteristik sosiodemografis dan metrik engagement [1]. Early warning system memperluas manfaat prediksi dengan menempatkan identifikasi risiko pada periode ketika intervensi akademik masih dapat dilakukan [2]. Ketersediaan informasi risiko pada minggu-minggu awal memberi ruang bagi dosen, tutor, dan pengelola program studi untuk merancang tindak lanjut yang relevan.

Sistem pembelajaran digital menghasilkan data akademik dan jejak aktivitas yang dapat digunakan untuk membaca engagement mahasiswa. Data tersebut mencakup interaksi dengan Virtual Learning Environment (VLE), partisipasi assessment, performa penilaian, dan informasi registrasi awal. Studi mengenai digital traces memperlihatkan bahwa pola aktivitas Learning Management System dapat membantu memahami variasi performa dan risiko mahasiswa [3]. Open University Learning Analytics Dataset (OULAD) menyediakan data tersebut dalam struktur relasional yang mencakup profil mahasiswa, assessment, registrasi, dan lebih dari sepuluh juta catatan aktivitas VLE [4].

Nilai prediktif suatu model bergantung pada kesesuaian data dengan waktu keputusan. Penggunaan aktivitas seluruh semester atau status unregistration menghasilkan informasi yang kuat untuk klasifikasi retrospektif, sedangkan early

warning memerlukan fitur yang telah tersedia pada waktu prediksi. Penelitian ini menggunakan cut-off hari ke-28 untuk merepresentasikan akhir minggu keempat. Assessment dan aktivitas VLE setelah cut-off dikeluarkan dari fitur, sedangkan status unregistration diperlakukan sebagai informasi masa depan. Pembatasan temporal tersebut menghasilkan estimasi performa yang lebih dekat dengan kondisi intervensi dini.

Literatur menunjukkan bahwa kemampuan mendeteksi mahasiswa berisiko perlu dihubungkan dengan proses tindak lanjut agar memberi dampak institusional [2]. Model machine learning menghasilkan kelas dan probabilitas, sedangkan pemangku kepentingan memerlukan alasan risiko, prioritas, dan rekomendasi yang dapat dibaca secara operasional. Kebutuhan tersebut membentuk research gap pada integrasi antara evaluasi model, interpretasi berbasis aturan, dan penyajian visual untuk decision support.

Penelitian ini bertujuan mengembangkan klasifikasi biner risiko ketidakberhasilan mahasiswa dalam mata kuliah pada minggu keempat, mengevaluasi tiga algoritma supervised learning, dan mengintegrasikan model terpilih dengan knowledge-based risk layer. Hasil sistem diterjemahkan menjadi dashboard Business Intelligence untuk monitoring risiko dan prioritas intervensi akademik pada tingkat module-presentation.

Kontribusi penelitian terdiri atas empat bagian. Pertama, penelitian membentuk dataset early warning pada unit student-module-presentation dengan cut-off hari ke-28. Kedua, evaluasi menggunakan pemisahan berbasis *id_student* untuk menjaga independensi mahasiswa antara data pelatihan dan pengujian. Ketiga, knowledge-based risk layer menghasilkan level, alasan risiko, dan rekomendasi berdasarkan prediksi model serta perilaku awal. Keempat, dashboard mengubah keluaran analitik menjadi indikator yang mendukung keputusan pimpinan akademik, program studi, tutor, dosen wali, dan tim konseling.

II. RELATED WORKS

Penelitian student dropout dan academic performance analytics memanfaatkan data akademik, sosiodemografis, dan aktivitas digital untuk memprediksi keberlanjutan studi serta hasil pembelajaran. Informasi awal seperti karakteristik sosiodemografis, riwayat akademik, dan engagement digital memiliki nilai prediktif terhadap retensi mahasiswa [1]. Pada OULAD, ruang lingkup target berada pada hasil akhir mata kuliah untuk setiap student-module-presentation.

Early warning system mengarahkan hasil prediksi pada proses intervensi. Plak et al. menunjukkan bahwa informasi risiko perlu disertai rancangan tindak lanjut agar dapat memengaruhi hasil akademik [2]. Shou et al. menggunakan OULAD untuk memprediksi performa mahasiswa melalui multidimensional time-series yang menggabungkan learning behavior, assessment score, dan informasi demografis. Pada 20% durasi course, model MTAPSP harian mencapai accuracy 0,9179 dan F1-score 0,9180 untuk target biner *Pass* serta *Distinction* terhadap *Fail* serta *Withdrawn* [5]. Temuan tersebut menegaskan bahwa horizon pengamatan menjadi bagian penting dalam membaca performa early warning.

Penelitian berbasis OULAD terus berkembang melalui kombinasi fitur assessment, aktivitas VLE, dan profil mahasiswa. Jawad et al. menerapkan Random Forest dengan SMOTE dan memperoleh testing accuracy 0,892 pada skenario 260 hari [6]. Balabied dan Eid melaporkan accuracy serta F1-score 0,90 menggunakan Random Forest [7]. Ujkani et al. memperoleh accuracy 0,93 menggunakan custom neural network [8], sedangkan KANFormer dari Alnasyan et al. mencapai accuracy 0,9459 dan F1-score 0,9481 [9]. Shou et al. [5], Ujkani et al. [8], dan Alnasyan et al. [9] memakai definisi target yang sebanding. Perbedaan horizon, split, balancing, dan arsitektur model tetap menentukan konteks perbandingan.

Pendekatan hybrid mengintegrasikan beberapa sumber data untuk identifikasi mahasiswa berisiko [10]. Penelitian lain mencakup early warning berbasis XGBoost [11], AutoML [12], precision education [13], phased prediction [14], pola penggunaan LMS [15], dan analisis lintas institusi [16]. Keragaman tersebut menunjukkan bahwa fitur, horizon waktu, dan konteks institusi menentukan interpretasi performa model.

Penelitian ini mengambil posisi pada integrasi tiga komponen. Supervised learning digunakan untuk menghasilkan probabilitas risiko, knowledge-based risk layer menerjemahkan probabilitas dan sinyal perilaku menjadi alasan serta level prioritas, dan dashboard menyajikan hasil sebagai visual decision support. Cut-off minggu keempat menjaga kesesuaian temporal antara fitur dan waktu intervensi. Integrasi tersebut menghubungkan evaluasi teknis dengan kebutuhan monitoring akademik yang dapat ditindaklanjuti.

III. METHODOLOGY

A. Research Design

Penelitian menggunakan supervised binary classification untuk mendeteksi risiko ketidakberhasilan mahasiswa dalam mata kuliah pada akhir minggu keempat. Alurnya mencakup audit OULAD, pembentukan fitur dengan cut-off temporal, exploratory data analysis, pemisahan berbasis mahasiswa, evaluasi model, knowledge-based risk layer, dan dashboard Business Intelligence. Seluruh eksperimen menggunakan *random_state=42*.

B. Dataset and Unit of Analysis

Open University Learning Analytics Dataset (OULAD) [4] diperoleh melalui UCI Machine Learning Repository. Tabel yang digunakan meliputi *studentInfo*, *studentRegistration*, *assessments*, *studentAssessment*, *studentVle*, *courses*, dan *vle*. *studentInfo* memuat 32.593 baris dan *studentVle* memuat 10.655.280 catatan aktivitas.

Satu baris hasil preprocessing merepresentasikan seorang mahasiswa pada satu kombinasi *code_module* dan *code_presentation*. Unit student-module-presentation ini mengikuti struktur label *studentInfo* dan penggabungan data registrasi, assessment, serta VLE.

C. Target Label and Temporal Cut-off

Target dirumuskan sebagai klasifikasi biner pada tingkat mata kuliah. Label *AtRisk* diberikan kepada baris dengan *final_result* berupa *Withdrawn* atau *Fail*. Label *Successful* diberikan kepada baris dengan *final_result* berupa *Pass* atau *Distinction*. Status tersebut menjelaskan hasil mahasiswa pada suatu module-presentation. Dataset terdiri atas 17.208 baris *AtRisk* dan 15.385 baris *Successful*.

Horizon early warning ditetapkan pada hari ke-28. Submission assessment dipilih dengan kondisi *date_submitted* ≤ 28 , sedangkan aktivitas VLE dipilih dengan kondisi *date* ≤ 28 . Informasi *date_unregistration*, *has_unregistration*, hasil akhir, dan aktivitas setelah hari ke-28 dikeluarkan dari fitur prediktor. Hasil akhir hanya digunakan untuk membentuk target evaluasi.

D. Feature Construction

Fitur kategorikal mencakup *gender*, *region*, *highest_education*, *imd_band*, *age_band*, *disability*, *code_module*, dan *code_presentation*. Fitur numerik awal mencakup *num_of_prev_attempts*, *studied_credits*, dan *date_registration*.

Data *studentAssessment* dihubungkan dengan tabel *assessments* melalui *id_assessment* untuk memperoleh konteks module-presentation. Data sampai hari ke-28 diagregasi menjadi *assessment_count*, *assessment_score_mean*, *assessment_score_max*, dan *assessment_score_min*. Data *studentVle* sampai hari ke-28 diagregasi menjadi *vle_total_clicks*, *vle_active_days*, *vle_site_count*, dan *vle_last_activity_day*.

Nilai numerik dikonversi menggunakan *pd.to_numeric* dengan nilai yang tidak dapat dikonversi diperlakukan sebagai missing value. Agregat perilaku yang belum memiliki aktivitas diisi dengan nol. Pada pipeline model, missing value numerik diimputasi menggunakan median dan kemudian distandardisasi. Missing value kategorikal diimputasi menggunakan modus dan ditransformasikan dengan one-hot encoding. Seluruh transformasi dipelajari di dalam pipeline pada data pelatihan.

E. Data Splitting and Validation

Data dibagi menjadi 80% train-validation dan 20% hold-out test menggunakan *GroupShuffleSplit*. Variabel *id_student* digunakan sebagai grup sehingga setiap mahasiswa ditempatkan secara eksklusif pada salah satu bagian. Train-validation terdiri atas 26.122 baris dan test terdiri atas 6.471 baris. Pemeriksaan menunjukkan overlap mahasiswa sebesar nol.

Evaluasi cross-validation menggunakan 5-fold *GroupKFold* pada train-validation. Pemilihan model didasarkan pada rata-rata recall kelas *AtRisk*, kemudian F1-score *AtRisk* digunakan sebagai tie-breaker. Setelah model terpilih, performa akhir dilaporkan pada hold-out test.

F. Supervised Learning Models

Tiga algoritma dibandingkan. Logistic Regression digunakan sebagai baseline linear dengan *class_weight='balanced'*. Random Forest menggunakan 250

pohon dan *class_weight='balanced'*. XGBoost menggunakan 200 estimator, kedalaman maksimum 4, learning rate 0,08, subsample 0,9, dan colsample 0,9. Nilai *scale_pos_weight* dihitung dari distribusi kelas train-validation.

Metrik evaluasi mencakup accuracy, precision, recall, dan F1-score untuk kelas *AtRisk*, ROC-AUC, confusion matrix, serta classification report. Recall *AtRisk* menjadi kriteria utama karena early warning memprioritaskan cakupan mahasiswa berisiko yang dapat diarahkan pada proses verifikasi dan intervensi.

G. Knowledge-Based Risk Layer

Knowledge-based risk layer menggunakan empat indikator: *assessment_score_mean*, *assessment_count*, *vle_total_clicks*, dan *vle_active_days*. Threshold dihitung dari kuartil bawah data train-validation. Prosedur ini menjaga threshold tetap independen dari hold-out test. Hasil perhitungan menghasilkan threshold skor assessment 0, jumlah assessment 0, total klik VLE 47, dan hari aktif VLE 4.

Sinyal risiko diberikan ketika nilai indikator berada pada atau di bawah threshold. Status *High Risk* diberikan ketika model memprediksi *AtRisk* dan mahasiswa memiliki minimal dua sinyal aturan. Status *Medium Risk* diberikan ketika model memprediksi *AtRisk* atau mahasiswa memiliki minimal dua sinyal aturan. Status *Low Risk* diberikan pada kondisi lainnya.

Setiap baris menghasilkan probabilitas *AtRisk*, jumlah sinyal, alasan risiko, dan rekomendasi intervensi. Aktivitas VLE rendah diarahkan pada pengingat dan monitoring akses. Assessment rendah atau belum dikerjakan diarahkan pada pendampingan akademik. Kombinasi minimal tiga sinyal diarahkan pada konseling atau tindak lanjut dosen wali.

Evaluasi sistem gabungan memetakan *High Risk* dan *Medium Risk* sebagai *AtRisk*, lalu mengukur perubahan cakupan deteksi, precision, dan beban verifikasi.

H. Visual Analytics and Business Intelligence

Dashboard statis dibangun menggunakan Matplotlib dan Seaborn. Dashboard memuat KPI mahasiswa unik, jumlah dan persentase prioritas intervensi, distribusi level risiko, risiko per module-presentation, distribusi probabilitas, sinyal dominan, median aktivitas VLE dan assessment, confusion matrix, serta perbandingan model dengan knowledge layer.

Daftar prioritas diurutkan berdasarkan level risiko, probabilitas *AtRisk*, dan jumlah sinyal. Keluaran tersebut mendukung beberapa tingkat keputusan. Pimpinan akademik memperoleh gambaran skala risiko, program studi melihat konsentrasi risiko antar module-presentation, dan tutor atau dosen wali memperoleh alasan serta rekomendasi pada tingkat mahasiswa. Sistem diposisikan sebagai decision support yang membantu stakeholder menetapkan tindak lanjut berdasarkan bukti analitik dan pertimbangan akademik.

IV. RESULTS AND DISCUSSION

A. Dataset and Validation Results

Dataset hasil preprocessing memuat 32.593 student-module-presentation dari 28.785 mahasiswa unik. Kelas *AtRisk* berjumlah 17.208 baris dan kelas *Successful* berjumlah

15.385 baris. Train-validation memuat 26.122 baris, sedangkan hold-out test memuat 6.471 baris dengan 3.398 kasus *AtRisk* dan 3.073 kasus *Successful*. Pemisahan berbasis *id_student* menghasilkan overlap mahasiswa sebesar nol. Missing value terutama terdapat pada *imd_band* dan sebagian kecil *date_registration*; keduanya ditangani di dalam pipeline berdasarkan data pelatihan pada setiap fold.

B. Cross-Validation Performance

Tabel I menunjukkan hasil 5-fold GroupKFold. Random Forest menghasilkan mean recall *AtRisk* tertinggi sebesar 0,7107 dan dipilih sebagai model final sesuai kriteria seleksi. XGBoost menghasilkan accuracy, F1-score, dan ROC-AUC tertinggi, masing-masing sebesar 0,7584, 0,7522, dan 0,8440.

TABLE I
HASIL 5-FOLD GROUPKFOLD PADA TRAIN-VALIDATION

Metrik	Logistic Regression	Random Forest	XGBoost
Accuracy	0,7496 ± 0,0039	0,7524 ± 0,0013	0,7584 ± 0,0024
Precision <i>AtRisk</i>	0,8090 ± 0,0059	0,7989 ± 0,0136	0,8215 ± 0,0096
Recall <i>AtRisk</i>	0,6889 ± 0,0064	0,7107 ± 0,0085	0,6938 ± 0,0029
F1 <i>AtRisk</i>	0,7442 ± 0,0059	0,7521 ± 0,0030	0,7522 ± 0,0039
ROC-AUC	0,8330 ± 0,0027	0,8362 ± 0,0023	0,8440 ± 0,0019

C. Hold-Out Test Performance

Pada hold-out test, Random Forest mencapai accuracy 0,7594, precision *AtRisk* 0,8007, recall 0,7213, F1-score 0,7589, dan ROC-AUC 0,8396. XGBoost menghasilkan accuracy dan ROC-AUC tertinggi, sedangkan Random Forest mempertahankan recall *AtRisk* tertinggi. Dari 3.398 kasus *AtRisk*, Random Forest mengenali 2.451 kasus dan melewati 947 kasus.

TABLE II
PERFORMA MODEL PADA HOLD-OUT TEST

Metrik	Logistic Regression	Random Forest	XGBoost
Accuracy	0,7487	0,7594	0,7611
Precision <i>AtRisk</i>	0,8034	0,8007	0,8154
Recall <i>AtRisk</i>	0,6904	0,7213	0,7045
F1 <i>AtRisk</i>	0,7426	0,7589	0,7559
ROC-AUC	0,8311	0,8396	0,8443

Fig. 1 membandingkan metrik ketiga model, Fig. 2 menunjukkan confusion matrix Random Forest, dan Fig. 3 menyajikan kurva ROC. Ketiga model memiliki kurva ROC yang berdekatan. Pemilihan Random Forest mengikuti tujuan early warning yang menempatkan cakupan deteksi *AtRisk* sebagai prioritas model selection.




Fig. 1. Perbandingan metrik model pada hold-out test.




Fig. 2. Confusion matrix Random Forest pada hold-out test.




Fig. 3. Kurva ROC model pada hold-out test.

D. Feature Importance

Kontribusi fitur Random Forest didominasi sinyal perilaku awal. Total klik VLE, hari aktivitas terakhir, jumlah hari aktif, dan ragam situs yang diakses muncul sebagai prediktor teratas, diikuti fitur assessment dan registrasi. Nilai importance menunjukkan kontribusi prediktif global; interpretasi hubungan sebab akibat memerlukan desain penelitian kausal.




Fig. 4. Lima belas fitur dengan feature importance tertinggi pada Random Forest.

E. Benchmark with OULAD Studies

Fig. 5 menempatkan hasil penelitian dalam konteks lima studi OULAD. Shou et al. memakai target biner yang sama pada 20% durasi course [5]. Jawad et al. menggunakan data sampai 260 hari dan SMOTE [6], Balabied dan Eid menggunakan Random Forest [7], sedangkan Ujkani et al. [8] dan Alnasyan et al. [9] menggabungkan *Fail* serta *Withdrawn* sebagai kelompok at-risk. Grafik menyajikan nilai yang dilaporkan setiap studi sebagai benchmark kontekstual karena horizon, split, balancing, dan model yang digunakan berbeda.




Fig. 5. Benchmark accuracy dan F1-score penelitian berbasis OULAD. Perbandingan bersifat kontekstual karena perbedaan horizon, data split, balancing, dan model.

F. Knowledge-Based Risk Layer and BI Output

Threshold kuartil bawah train-validation adalah skor assessment 0, jumlah assessment 0, total klik VLE 47, dan hari aktif VLE 4. Knowledge layer menghasilkan 1.816 *High Risk*, 1.979 *Medium Risk*, dan 2.676 *Low Risk*. Ketika *High Risk* serta *Medium Risk* dipetakan sebagai alarm *AtRisk*, recall meningkat dari 0,7213 menjadi 0,7866; precision berubah dari 0,8007 menjadi 0,7043. Perubahan tersebut memperluas cakupan alarm dan menambah kebutuhan verifikasi stakeholder.

TABLE III
PERBANDINGAN MODEL DAN KNOWLEDGE-BASED RISK LAYER

Metrik	Random Forest	RF + Knowledge Layer
Accuracy	0,7594	0,7146
Precision AtRisk	0,8007	0,7043
Recall AtRisk	0,7213	0,7866
F1 AtRisk	0,7589	0,7432

Dashboard pada Fig. 6 mengidentifikasi 3.795 student-module-presentation dalam antrean *High Risk* atau *Medium Risk*. Sinyal terbanyak adalah skor assessment rendah dengan 2.341 kasus. Daftar prioritas memuat identitas anonim, module-presentation, probabilitas *AtRisk*, level, jumlah sinyal, alasan, dan rekomendasi. Struktur ini menghubungkan evaluasi teknis dengan monitoring module-presentation dan tindak lanjut tingkat mahasiswa.




Fig. 6. Dashboard early warning OULAD pada akhir minggu keempat.

G. Discussion and Limitations

Hasil eksperimen memperlihatkan hubungan antara tujuan keputusan dan model selection. XGBoost unggul pada accuracy dan ROC-AUC, sementara Random Forest memperoleh recall *AtRisk* tertinggi pada cross-validation dan hold-out test. Performa sekitar 0,76 merepresentasikan skenario awal yang hanya menggunakan informasi sampai hari ke-28. Horizon ini menyediakan waktu intervensi lebih panjang sekaligus membatasi jumlah bukti perilaku yang tersedia bagi model.

Threshold assessment sebesar nol menunjukkan bahwa sebagian module-presentation belum memiliki submission sampai minggu keempat. Pengembangan berikutnya dapat menggunakan threshold per module-presentation atau menyesuaikan cut-off dengan jadwal assessment. Knowledge layer memperluas recall sebesar 0,0653 poin dan menghasilkan alasan operasional seperti aktivitas VLE rendah atau assessment yang belum dikerjakan. Alasan tersebut

menjadi bahan verifikasi bersama informasi kontekstual dari dosen dan tutor.

Dashboard memperluas fungsi model menjadi Business Intelligence melalui agregasi risiko, perbandingan module-presentation, dan antrean mahasiswa. Temuan 100% prioritas pada GGG 2014J menjadi sinyal untuk meninjau ukuran kelompok, jadwal assessment, serta karakteristik modul sebelum menentukan tindakan.

Keterbatasan penelitian mencakup konteks OULAD di Open University Inggris, fitur perilaku yang masih berupa agregat, konfigurasi model baseline, dan threshold kuartil yang memerlukan validasi pakar. Evaluasi mengukur performa deteksi, sedangkan dampak intervensi terhadap keberhasilan mata kuliah memerlukan penelitian lanjutan dengan data institusi dan desain evaluasi intervensi.

V. CONCLUSION

Penelitian ini mengembangkan early warning risiko ketidakberhasilan mahasiswa dalam mata kuliah pada akhir minggu keempat menggunakan OULAD. Dataset dibentuk pada unit student-module-presentation dengan fitur demografis, registrasi awal, assessment, dan aktivitas VLE sampai hari ke-28. Pemisahan berbasis *id_student* menjaga independensi mahasiswa antara train-validation dan hold-out test.

Random Forest dipilih berdasarkan recall *AtRisk* cross-validation tertinggi sebesar 0,7107. Pada hold-out test, model menghasilkan accuracy 0,7594, precision 0,8007, recall 0,7213, F1-score 0,7589, dan ROC-AUC 0,8396. Knowledge-based risk layer meningkatkan recall menjadi 0,7866 dengan menggabungkan prediksi model dan empat sinyal perilaku awal. Sistem menghasilkan level risiko, alasan, dan rekomendasi yang dapat diterjemahkan menjadi antrean intervensi.

Dashboard Business Intelligence menyajikan distribusi risiko, prioritas module-presentation, sinyal dominan, performa model, dan daftar mahasiswa anonim untuk monitoring. Integrasi supervised learning, knowledge-based risk layer, dan visual analytics menghasilkan decision support yang menghubungkan prediksi dengan proses tindak lanjut akademik.

Pengembangan berikutnya dapat membandingkan horizon minggu keempat, kedelapan, dan kedua belas; menggunakan threshold per module-presentation; melakukan tuning hyperparameter; serta menguji validitas eksternal pada data institusi lain. Evaluasi dampak intervensi juga diperlukan untuk mengukur kontribusi sistem terhadap keberhasilan mahasiswa menyelesaikan mata kuliah.

REFERENCES

- [1] S. Matz et al., "Using machine learning to predict student retention from socio-demographic characteristics and app-based engagement metrics," *Scientific Reports*, 2023, doi: 10.1038/s41598-023-32484-w.
- [2] S. Plak et al., "Early warning systems for more effective student counselling in higher education: Evidence from a Dutch field experiment," *Higher Education Quarterly*, 2022, doi: 10.1111/hequ.12298.
- [3] J. Pecuchova and M. Drlik, "Enhancing the Early Student Dropout Prediction Model Through Clustering Analysis of Students' Digital Traces," *IEEE Access*, 2024, doi: 10.1109/ACCESS.2024.3486762.
- [4] J. Kuzilek, M. Hlosta, and Z. Zdrahal, "Open University Learning Analytics dataset," *Scientific Data*, vol. 4, article no. 170171, 2017, doi: 10.1038/sdata.2017.171.
- [5] Z. Shou, M. Xie, J. Mo, and H. Zhang, "Predicting Student Performance in Online Learning: A Multidimensional Time-Series Data Analysis Approach," *Applied Sciences*, vol. 14, no. 6, article no. 2522, 2024, doi: 10.3390/app14062522.
- [6] K. Jawad, M. A. Shah, and M. Tahir, "Students' Academic Performance and Engagement Prediction in a Virtual Learning Environment Using Random Forest with Data Balancing," *Sustainability*, vol. 14, no. 22, article no. 14795, 2022, doi: 10.3390/su142214795.
- [7] S. A. A. Balabied and H. F. Eid, "Utilizing Random Forest Algorithm for Early Detection of Academic Underperformance in Open Learning Environments," *PeerJ Computer Science*, vol. 9, article no. e1708, 2023, doi: 10.7717/peerj-cs.1708.
- [8] B. Ujkani, D. Minkovska, and N. Hinov, "Course Success Prediction and Early Identification of At-Risk Students Using Explainable Artificial Intelligence," *Electronics*, vol. 13, no. 21, article no. 4157, 2024, doi: 10.3390/electronics13214157.
- [9] B. Alnasyan, M. Basher, M. Allassafi, and K. Alnasyan, "Kanformer: An Attention-Enhanced Deep Learning Model for Predicting Student Performance in Virtual Learning Environments," *Social Network Analysis and Mining*, vol. 15, article no. 25, 2025, doi: 10.1007/s13278-025-01446-7.
- [10] T. Kustitskaya et al., "Hybrid Approach to Predicting Learning Success Based on Digital Educational History for Timely Identification of At-Risk Students," *Education Sciences*, 2024, doi: 10.3390/educsci14060657.
- [11] M. Carballo-Mendivil et al., "Predicting Student Dropout from Day One: XGBoost-Based Early Warning System Using Pre-Enrollment Data," *Applied Sciences*, 2025, doi: 10.3390/app15169202.
- [12] A. Garpis et al., "Assisting Educational Analytics with AutoML Functionalities," *Computers*, 2022, doi: 10.3390/computers11060097.
- [13] C. Y. Tsai et al., "Precision education with statistical learning and deep learning: a case study in Taiwan," *International Journal of Educational Technology in Higher Education*, 2020, doi: 10.1186/s41239-020-00186-2.
- [14] M. V. Martins et al., "Multi-Class Phased Prediction of Academic Performance and Dropout in Higher Education," *Applied Sciences*, 2023, doi: 10.3390/app13084702.
- [15] J. R. Rico-Juan et al., "Study regarding the influence of a student's personality and an LMS usage profile on learning performance using machine learning techniques," *Applied Intelligence*, 2024, doi: 10.1007/s10489-024-05483-1.
- [16] J. Berens et al., "Crossing individual university boundaries: a comprehensive approach to predicting dropouts in the higher education system," *Higher Education*, 2025, doi: 10.1007/s10734-025-01509-w.