

Analisis Risiko Dropout Mahasiswa Menggunakan Supervised Learning dan Knowledge-Based Risk Layer pada Open University Learning Analytics Dataset

Muhammad Rizky Hajar
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
riskihajar@students.amikom.ac.id

Alwie Muflich
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
alwiemuflich@students.amikom.ac.id

Heri Santosa
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
heri.santi@students.amikom.ac.id

Andi Sunyoto
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
andi.sunyoto@amikom.ac.id

Robert Marco
Department of Computer Science
Universitas Amikom Yogyakarta
Yogyakarta, Indonesia
robert.marco@amikom.ac.id

Abstract— Dropout mahasiswa merupakan salah satu persoalan penting dalam pengelolaan pendidikan tinggi karena dapat berdampak pada capaian akademik mahasiswa, efektivitas layanan akademik, dan evaluasi kinerja institusi. Penelitian ini merancang analisis risiko dropout mahasiswa menggunakan pendekatan supervised learning pada Open University Learning Analytics Dataset (OULAD).

Framing masalah yang digunakan adalah klasifikasi biner dengan label AtRisk untuk mahasiswa dengan hasil akhir Withdrawn dan Fail, serta Successful untuk mahasiswa dengan hasil akhir Pass dan Distinction. Dataset dibentuk dengan unit analisis satu mahasiswa pada satu kombinasi modul dan presentation, kemudian diperkaya menggunakan fitur demografis, registrasi, penilaian, dan aktivitas pembelajaran virtual.

Selain model machine learning, penelitian ini mengusulkan knowledge-based risk layer berbasis aturan untuk memberikan interpretasi tambahan terhadap faktor risiko, seperti aktivitas VLE yang rendah, performa penilaian yang lemah, dan sinyal unregistration. Rancangan ini diarahkan agar hasil klasifikasi tidak berhenti sebagai label prediksi, tetapi dapat diterjemahkan menjadi indikator early warning dan decision support dalam konteks Business Intelligence.

Keywords— student dropout, supervised learning, OULAD, early warning system, knowledge-based system, business intelligence.

I. PENDAHULUAN

Dropout mahasiswa menjadi salah satu isu penting dalam pendidikan tinggi karena berkaitan dengan keberlanjutan studi, kualitas layanan akademik, dan efektivitas pengambilan keputusan institusional. Penelitian sebelumnya menunjukkan bahwa machine learning dapat digunakan untuk memprediksi retensi mahasiswa dengan memanfaatkan karakteristik sosiodemografis dan metrik engagement [1]. Pendekatan berbasis early warning juga semakin banyak digunakan karena institusi perlu mengenali mahasiswa berisiko sebelum masalah akademik berkembang menjadi kegagalan studi [2]. Ketika risiko kegagalan studi baru diketahui pada akhir periode pembelajaran, ruang intervensi akademik menjadi terbatas.

Perkembangan sistem pembelajaran digital membuka peluang baru untuk menganalisis risiko akademik secara lebih sistematis. Data mahasiswa tidak hanya berasal dari informasi

demografis atau hasil akademik akhir, tetapi juga dari jejak aktivitas digital, seperti interaksi dengan Virtual Learning Environment (VLE), jumlah aktivitas belajar, riwayat penilaian, dan status registrasi. Studi terkait digital traces memperlihatkan bahwa pola aktivitas LMS dapat membantu memahami kelompok mahasiswa berisiko dan memperkuat prediksi dropout [3]. OULAD menyediakan data semacam ini dalam bentuk dataset learning analytics terbuka yang banyak digunakan untuk penelitian pendidikan berbasis data [4]. Agar bermanfaat bagi pengambil keputusan akademik, data tersebut perlu diolah menjadi indikator monitoring, early warning, dan dasar pengambilan keputusan berbasis data.

Meskipun model prediktif banyak digunakan dalam penelitian dropout, beberapa studi menunjukkan bahwa akurasi prediksi saja belum cukup untuk menjamin keberhasilan intervensi akademik [2]. Banyak penelitian masih berfokus pada performa model, sementara pemanfaatan hasil prediksi sebagai indikator yang mudah dipahami untuk monitoring dan decision support belum selalu dijelaskan secara operasional. Permasalahan utama yang diangkat dalam artikel ini adalah bagaimana merancang pendekatan klasifikasi risiko dropout mahasiswa berbasis data akademik dan aktivitas pembelajaran digital, sekaligus menambahkan lapisan knowledge-based agar hasil prediksi lebih mudah dijelaskan kepada pemangku kepentingan akademik.

Penelitian ini bertujuan merancang klasifikasi biner risiko mahasiswa menggunakan OULAD dengan label AtRisk dan Successful, menyusun skenario eksperimen supervised learning, serta mengusulkan knowledge-based risk layer sebagai lapisan interpretasi berbasis aturan. Rancangan tersebut disusun agar hasil analitik dapat menjadi dasar bagi pengembangan early warning dan visual decision support pada lingkungan akademik.

Penelitian ini memberikan tiga kontribusi utama. Pertama, penelitian merumuskan framing risiko dropout mahasiswa pada OULAD dalam bentuk klasifikasi biner yang relevan untuk early warning. Kedua, penelitian menyusun rancangan fitur dari data demografis, registrasi, assessment, dan aktivitas VLE. Ketiga, penelitian mengusulkan integrasi model supervised learning dengan rule-based risk layer agar keluaran model tidak hanya berupa prediksi kelas, tetapi juga dapat dijelaskan melalui indikator risiko yang lebih operasional.

II. TINJAUAN PUSTAKA

Penelitian mengenai student dropout analytics umumnya berfokus pada pemanfaatan data akademik, sosiodemografis, dan aktivitas digital untuk memprediksi risiko kegagalan studi. Beberapa studi menunjukkan bahwa informasi awal mahasiswa, seperti karakteristik sosiodemografis, riwayat akademik, dan engagement digital, dapat digunakan untuk memprediksi retensi atau dropout sejak periode awal studi [1], [5]. Pendekatan ini penting karena semakin awal mahasiswa berisiko teridentifikasi, semakin besar peluang institusi untuk menyusun intervensi akademik yang tepat.

Studi terkait machine learning untuk prediksi retensi mahasiswa menunjukkan bahwa kombinasi data institusional dan metrik engagement dapat meningkatkan kemampuan model dalam mendeteksi mahasiswa berisiko [1]. Penelitian lain mengembangkan pendekatan hybrid berbasis digital educational history untuk mengidentifikasi at-risk students secara lebih dini [5]. Kedua arah penelitian tersebut memperlihatkan bahwa risiko dropout tidak hanya dipengaruhi oleh satu jenis data, tetapi oleh gabungan faktor akademik, perilaku belajar, dan konteks mahasiswa.

Early warning system juga menjadi tema penting dalam literatur. Sistem peringatan dini dapat membantu konselor atau pihak akademik memprioritaskan mahasiswa yang membutuhkan perhatian. Namun, Plak et al. menunjukkan bahwa kemampuan mengidentifikasi mahasiswa berisiko tidak otomatis menurunkan dropout jika tidak disertai rancangan intervensi yang efektif [2]. Temuan tersebut menunjukkan bahwa model prediksi perlu dihubungkan dengan strategi tindak lanjut, visualisasi, dan proses pengambilan keputusan agar manfaatnya dapat dirasakan secara institusional.

Aktivitas pada Learning Management System atau VLE banyak digunakan sebagai sumber fitur karena mencerminkan pola belajar mahasiswa. Penelitian mengenai digital traces menunjukkan bahwa data klik, frekuensi aktivitas, jenis aktivitas, dan pola interaksi dapat membantu mengelompokkan maupun memprediksi performa mahasiswa [3]. Pada penelitian lain, XGBoost digunakan untuk membangun early warning system berbasis data pra-enrollment [6], AutoML digunakan untuk membantu proses educational analytics [7], sedangkan statistical learning dan deep learning digunakan untuk mendukung pendekatan precision education [8]. Random Forest juga banyak digunakan dalam prediksi bertahap performa akademik dan dropout karena sesuai untuk data tabular dengan fitur akademik maupun sosiodemografis [9].

Penelitian lain juga memperlihatkan bahwa personality, engagement, dan pola penggunaan LMS dapat membantu identifikasi risiko kegagalan akademik, sedangkan data administratif lintas institusi dapat memperluas cakupan prediksi dropout pada level sistem pendidikan tinggi [10], [11]. Meskipun banyak penelitian telah membahas akurasi model, masih terdapat celah pada sisi pemanfaatan hasil analitik untuk kebutuhan Business Intelligence. Banyak studi berhenti pada evaluasi model, sementara aspek interpretasi operasional, monitoring risiko, dan dukungan keputusan belum selalu dijelaskan secara rinci. Berdasarkan gap tersebut, penelitian ini menghubungkan rancangan supervised learning dengan knowledge-based risk layer. Lapisan berbasis aturan tersebut diharapkan dapat menjembatani keluaran model

dengan indikator risiko yang lebih mudah dipahami dalam konteks dashboard dan early warning akademik.

III. METODOLOGI

A. Research Design

Penelitian ini dirancang sebagai penelitian supervised learning untuk klasifikasi risiko mahasiswa. Fokus metodologi mencakup pemilihan dataset, preprocessing, pembentukan fitur, rancangan model, knowledge-based risk layer, dan pemetaan keluaran model ke indikator Business Intelligence. Dengan alur tersebut, penelitian tidak hanya menyiapkan prediksi risiko, tetapi juga menyiapkan cara membaca hasil prediksi sebagai dasar monitoring akademik.

Alur penelitian yang direncanakan terdiri dari lima tahap utama. Tahap pertama adalah pemilihan dan audit dataset. Tahap kedua adalah preprocessing dan pembentukan dataset tabular. Tahap ketiga adalah pemodelan supervised learning menggunakan beberapa algoritma baseline. Tahap keempat adalah penambahan knowledge-based risk layer. Tahap kelima adalah evaluasi dan interpretasi hasil untuk mendukung kebutuhan early warning dan Business Intelligence. Dengan pembatasan tersebut, metode utama penelitian ditempatkan sebagai supervised binary classification, sedangkan dashboard dan clustering diperlakukan sebagai pengembangan lanjutan.

B. Dataset

Dataset yang digunakan adalah Open University Learning Analytics Dataset (OULAD) [4]. Dataset ini dipilih karena memiliki data akademik dan aktivitas pembelajaran digital yang relevan untuk analisis risiko mahasiswa. OULAD terdiri dari beberapa tabel, antara lain studentInfo, studentRegistration, studentAssessment, dan studentVle. Berdasarkan audit awal, tabel studentInfo memiliki 32.593 baris, sedangkan studentVle memiliki lebih dari 10 juta catatan aktivitas pembelajaran.

Unit analisis yang digunakan adalah satu mahasiswa pada satu kombinasi code_module dan code_presentation. Dengan demikian, satu baris dataset hasil preprocessing merepresentasikan satu student-module-presentation. Unit ini dipilih karena sesuai dengan struktur label pada studentInfo dan memungkinkan penggabungan data registrasi, assessment, serta aktivitas VLE secara konsisten.

C. Target Label

Target penelitian dirumuskan sebagai klasifikasi biner. Label AtRisk diberikan untuk mahasiswa dengan final_result berupa Withdrawn atau Fail. Label Successful diberikan untuk mahasiswa dengan final_result berupa Pass atau Distinction. Formulasi ini dipilih karena lebih sesuai dengan tujuan early warning dibandingkan klasifikasi multi-kelas penuh.

Berdasarkan dataset hasil preprocessing, jumlah data pada kelas AtRisk adalah 17.208 baris, sedangkan kelas Successful adalah 15.385 baris. Distribusi ini menunjukkan bahwa kedua kelas memiliki jumlah data yang memadai untuk skenario klasifikasi biner.

D. Feature Construction

Fitur dibentuk dari beberapa sumber data. Dari `studentInfo`, fitur yang digunakan mencakup `gender`, `region`, `highest education`, `IMD band`, `age band`, jumlah percobaan sebelumnya, jumlah kredit yang dipelajari, dan `disability`. Dari `studentRegistration`, fitur utama yang digunakan adalah tanggal registrasi, tanggal unregistration, serta flag `has_unregistration`.

Dari `studentAssessment`, fitur diagregasi menjadi jumlah `assessment`, rata-rata skor, skor maksimum, dan skor minimum. Agregasi `assessment` dirancang untuk dihubungkan dengan tabel `assessments` agar perhitungan skor mengikuti unit `code_module`, `code_presentation`, dan `id_student`. Dari `studentVle`, fitur diagregasi menjadi total klik, jumlah hari aktif, jumlah site yang diakses, dan hari aktivitas terakhir. Nilai `imd_band` yang kosong diisi dengan kategori `Unknown`, sedangkan nilai numerik hasil agregasi disiapkan agar dapat digunakan oleh model supervised learning.

E. Supervised Learning Scenario

Skenario supervised learning yang direncanakan menggunakan minimal tiga algoritma pembandingan. Algoritma baseline pertama adalah Logistic Regression karena dapat memberikan model awal yang sederhana dan mudah diinterpretasikan. Algoritma kedua adalah Random Forest karena mampu menangani hubungan non-linear dan fitur campuran pada data tabular, serta sering digunakan pada penelitian prediksi performa akademik bertahap [9]. Algoritma ketiga adalah XGBoost atau Gradient Boosting karena sering digunakan pada kasus klasifikasi tabular dan telah digunakan dalam studi prediksi dropout berbasis data pra-enrollment [6].

Evaluasi model dirancang menggunakan pembagian data train-test dan metrik seperti `accuracy`, `precision`, `recall`, `F1-score`, dan `confusion matrix`. Karena tujuan penelitian berkaitan dengan deteksi mahasiswa berisiko, metrik `recall` untuk kelas `AtRisk` perlu diberi perhatian khusus agar model tidak terlalu banyak melewatkan mahasiswa yang berpotensi gagal atau `withdrawn`.

F. Knowledge-Based Risk Layer

Knowledge-based risk layer dirancang sebagai lapisan tambahan berbasis aturan yang berjalan setelah fitur risiko terbentuk. Lapisan ini tidak menggantikan model supervised learning, tetapi berfungsi sebagai mekanisme interpretasi dan pendukung keputusan. Aturan disusun berdasarkan indikator yang relevan secara akademik, seperti `engagement VLE`, `performa assessment`, dan sinyal `unregistration`. Masukan utama lapisan ini adalah `assessment_score_mean`, `assessment_count`, `vle_total_clicks`, `vle_active_days`, `vle_last_activity_day`, dan `has_unregistration`.

Output knowledge-based layer dirancang dalam tiga tingkat, yaitu `High Risk`, `Medium Risk`, dan `Low Risk`. Threshold awal ditentukan menggunakan kuartil bawah dari dataset hasil preprocessing. Skor `assessment` dianggap rendah apabila `assessment_score_mean` kurang dari 50,29. Partisipasi `assessment` dianggap sangat rendah apabila `assessment_count` kurang dari 2. Aktivitas VLE dianggap

rendah apabila `vle_total_clicks` kurang dari 142 atau `vle_active_days` kurang dari 11. Sinyal `unregistration` ditandai ketika `has_unregistration` bernilai 1.

Mahasiswa diberi indikator `High Risk` apabila memiliki sinyal `unregistration` dan minimal dua indikator akademik atau VLE berada pada kondisi risiko. Mahasiswa diberi indikator `Medium Risk` apabila memiliki dua indikator risiko tanpa sinyal `unregistration`, atau satu indikator risiko dengan sinyal `unregistration`. Mahasiswa diberi indikator `Low Risk` apabila kondisi `High Risk` dan `Medium Risk` tidak terpenuhi. Threshold tersebut bersifat baseline awal dan dapat dievaluasi ulang setelah eksperimen model dilakukan.

Integrasi dengan model supervised learning dilakukan dengan menempatkan knowledge-based layer sebagai penjabar hasil prediksi. Jika model memprediksi mahasiswa sebagai `AtRisk`, rule layer digunakan untuk menunjukkan indikator yang mendukung prediksi tersebut. Jika model memprediksi mahasiswa sebagai `Successful` tetapi rule layer memberi status `High Risk`, data mahasiswa tersebut dapat ditandai sebagai kasus yang perlu ditinjau ulang dalam dashboard atau analisis lanjutan. Dalam konteks decision support, status `High Risk` diarahkan sebagai prioritas monitoring tinggi, `Medium Risk` sebagai mahasiswa yang perlu observasi berkala, dan `Low Risk` sebagai mahasiswa yang cukup dipantau secara reguler. Dengan cara ini, keluaran sistem tidak hanya berupa label prediksi, tetapi juga alasan risiko yang dapat dibaca oleh pihak akademik.

Kebijakan pendekatan knowledge-based adalah hasilnya mudah dijelaskan kepada pihak akademik, dapat dihubungkan dengan dashboard, dan membantu menerjemahkan keluaran model menjadi indikator tindakan. Kekurangannya adalah aturan dapat bersifat kaku, bergantung pada ambang batas yang ditentukan, dan perlu divalidasi ulang jika konteks data atau kebijakan akademik berubah. Oleh karena itu, lapisan aturan ini dirancang sebagai pelengkap model data-driven, bukan sebagai satu-satunya mekanisme prediksi.

G. Visual Analytics and BI Scenario

Keluaran model dirancang sebagai dasar indikator monitoring akademik, sehingga hasil klasifikasi tidak hanya dipahami sebagai metrik teknis, tetapi juga sebagai informasi pendukung keputusan. Rancangan visual analytics memuat jumlah mahasiswa `AtRisk`, distribusi `High Risk`, `Medium Risk`, dan `Low Risk`, perbandingan risiko antar module-presentation, ringkasan aktivitas VLE, serta ringkasan performa `assessment`. Indikator tersebut dapat digunakan untuk membantu pihak akademik melihat prioritas intervensi tanpa harus membaca seluruh detail teknis model.

Dashboard berperan sebagai media penyajian indikator decision support, sedangkan kontribusi metodologis tetap berfokus pada supervised binary classification dan knowledge-based risk layer. Dengan posisi tersebut, visual analytics menjadi bentuk pemanfaatan hasil analitik. Evaluasi tidak hanya melihat `accuracy`, `precision`, `recall`, dan `F1-score`, tetapi juga apakah keluaran risiko dapat dipetakan menjadi indikator yang actionable untuk monitoring akademik.

H. Research Scenario

Skenario penelitian diarahkan untuk membandingkan beberapa algoritma supervised learning, menganalisis fitur yang paling berkontribusi terhadap risiko, dan mengintegrasikan prediksi model dengan knowledge-based risk layer. Hasil yang diharapkan adalah model klasifikasi risiko yang dapat dijelaskan dan dapat menjadi dasar visualisasi early warning dalam konteks Business Intelligence.

IV. HASIL DAN DISKUSI

V. KESIMPULAN

REFERENSI

- [1] S. C. Matz, C. S. Bukow, H. Peters, C. Deacons, C. Stachl, dan others, "Using machine learning to predict student retention from socio-demographic characteristics and app-based engagement metrics," *Scientific Reports*, 2023, doi: 10.1038/s41598-023-32484-w.
- [2] S. Plak, I. Cornelisz, M. Meeter, dan C. van Klaveren, "Early warning systems for more effective student counselling in higher education: Evidence from a Dutch field experiment," *Higher Education Quarterly*, 2022, doi: 10.1111/hequ.12298.
- [3] J. Pecuchová dan M. Drlik, "Enhancing the Early Student Dropout Prediction Model Through Clustering Analysis of Students Digital Traces," *IEEE Access*, 2024, doi: 10.1109/ACCESS.2024.3486762.
- [4] J. Kuzilek, M. Hlosta, dan Z. Zdrahal, "Open University Learning Analytics dataset," *Scientific Data*, vol. 4, hlm. 170171, 2017, doi: 10.1038/sdata.2017.171.
- [5] T. A. Kustitskaya, R. V. Esin, dan others, "Hybrid Approach to Predicting Learning Success Based on Digital Educational History for Timely Identification of At-Risk Students," *Education Sciences*, vol. 14, no. 6, hlm. 657, 2024, doi: 10.3390/educsci14060657.
- [6] B. Carballo-Mendivil, A. Arellano-González, M. del P. Lizárraga-Díaz, dan N. Ríos-Félix, "Predicting Student Dropout from Day One: XGBoost-Based Early Warning System Using Pre-Enrollment Data," *Applied Sciences*, vol. 15, no. 16, hlm. 9202, 2025, doi: 10.3390/app15169202.
- [7] S. Garmpis, M. Maragoudakis, dan A. Garmpis, "Assisting Educational Analytics with AutoML Functionalities," *Computers*, vol. 11, no. 6, hlm. 97, 2022, doi: 10.3390/computers11060097.
- [8] S. C. Tsai, C. H. Chen, Y. T. Shiao, dan others, "Precision education with statistical learning and deep learning: a case study in Taiwan," *International Journal of Educational Technology in Higher Education*, vol. 17, hlm. 12, 2020, doi: 10.1186/s41239-020-00186-2.
- [9] M. V. Martins, L. Baptista, J. Machado, dan V. Realinho, "Multi-Class Phased Prediction of Academic Performance and Dropout in Higher Education," *Applied Sciences*, vol. 13, no. 8, hlm. 4702, 2023, doi: 10.3390/app13084702.
- [10] J. R. Rico-Juan, C. Cachero, dan H. Macià, "Study regarding the influence of a students personality and an LMS usage profile on learning performance using machine learning techniques," *Applied Intelligence*, vol. 54, hlm. 6175–6197, 2024, doi: 10.1007/s10489-024-05483-1.
- [11] J. Berens, A. Diem, L. Rumert, K. Schneider, dan S. C. Wolter, "Crossing individual university boundaries: a comprehensive approach to predicting dropouts in the higher education system," *Higher Education*, 2025, doi: 10.1007/s10734-025-01509-w.