

Early Warning Risiko Mahasiswa OULAD

Evaluasi Model, Knowledge-Based System, dan Dashboard DVBI

Mata Kuliah: Data Visualization and Business Intelligence

Kelompok: 5

Program Studi: S2 PJJ Informatika, Konsentrasi Big Data dan Predictive Analytics

Institusi: Universitas Amikom Yogyakarta

Nama	NIM
Muhammad Rizky Hajar	24.55.2714
Alwie Muflich	24.55.2667
Heri Santosa	24.55.2676

Ringkasan Penelitian


Penelitian ini membangun *early warning system* untuk mengenali mahasiswa yang berisiko memperoleh hasil akhir **Withdrawn** atau **Fail** sejak akhir minggu ke-4. Data yang digunakan adalah OULAD (*Open University Learning Analytics Dataset*), dengan informasi profil, registrasi, assessment, dan aktivitas pada VLE (*Virtual Learning Environment*). Informasi sampai hari ke-28 digunakan sebagai masukan agar peringatan dapat ditindaklanjuti.

Masalah ini berada pada ranah *predictive analytics*, yaitu penggunaan data untuk memperkirakan kondisi yang akan terjadi. Metode yang digunakan adalah *supervised binary classification*: model belajar dari data berlabel untuk membedakan **AtRisk** (**Withdrawn** atau **Fail**) dan **Successful** (**Pass** atau **Distinction**). Label hasil akhir tersebut menjadi dasar proses klasifikasi.

Tiga model pembandingan, Logistic Regression, Random Forest, dan XGBoost, dievaluasi menggunakan group-based student split dan 5-fold cross-validation, yaitu evaluasi berulang pada lima pembagian training data dan validation data. Model final dipilih berdasarkan recall **AtRisk**, yaitu proporsi mahasiswa yang benar-benar berisiko dan berhasil dikenali, karena mahasiswa berisiko yang terlewat merupakan perhatian utama dalam early warning.

Keluaran penelitian meliputi evaluasi model, *knowledge-based risk layer*, dan dashboard. Knowledge layer adalah aturan yang menggabungkan prediksi model, probabilitas risiko, serta sinyal assessment dan VLE untuk menyusun prioritas **High**, **Medium**, atau **Low Risk**. Hasil ini berfungsi sebagai *decision support* atau alat bantu pengambilan keputusan; dosen dan pengelola akademik melakukan verifikasi sebelum intervensi.

Alur Analitik Penelitian



Model menghasilkan dua kelas: `Successful` dan `AtRisk`. Level `High Risk`, `Medium Risk`, dan `Low Risk` dibentuk setelah prediksi dengan menggabungkan hasil model dan sinyal perilaku awal. Level tersebut menyusun urutan tindak lanjut melalui aturan knowledge layer.

`P(AtRisk)` berarti probabilitas kelas `AtRisk` menurut model. Nilai ini membantu mengurutkan prioritas, sedangkan keputusan intervensi tetap mempertimbangkan sinyal perilaku dan verifikasi oleh pengelola akademik.

1. Konfigurasi Analisis

Analisis menggunakan library untuk pengolahan data, visualisasi, preprocessing, evaluasi, dan tiga algoritma klasifikasi. `RANDOM_STATE=42` menjaga data split tetap dapat direproduksi, sedangkan `CUTOFF_DAY=28` menetapkan observation horizon pada akhir minggu ke-4.

Alasan cut-off: cut-off adalah batas waktu data yang boleh digunakan model. Hari ke-28 merepresentasikan akhir minggu ke-4, yaitu fase awal yang masih memberi ruang bagi dosen atau tutor untuk melakukan intervensi. Pada titik ini, data assessment dan aktivitas VLE awal sudah mulai terbentuk sehingga dapat digunakan sebagai sinyal prediktif awal.

Parameter ini menjaga eksperimen dapat dijalankan kembali dengan horizon observasi yang sama.

```
In [1]: # Library standar untuk file, download, ekstraksi zip, dan pengaturan
warning.
import os, shutil, urllib.request, zipfile, warnings
from pathlib import Path
from collections import Counter

# Library utama untuk manipulasi data dan visualisasi.
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```

# Komponen scikit-learn dan XGBoost untuk preprocessing, model, split, dan evaluasi.
from sklearn.base import clone
from sklearn.compose import ColumnTransformer
from sklearn.ensemble import RandomForestClassifier
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (accuracy_score, classification_report,
                             confusion_matrix,
                             f1_score, precision_score, recall_score,
                             roc_auc_score,
                             roc_curve)
from sklearn.model_selection import GroupKFold, GroupShuffleSplit
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from xgboost import XGBClassifier

# Pengaturan tampilan agar output notebook lebih rapi saat dipresentasikan.
warnings.filterwarnings('ignore')
sns.set_theme(style='whitegrid', palette='Set2')
pd.set_option('display.max_columns', 100)

# Parameter eksperimen: seed reproduksibilitas dan batas early warning
minggu ke-4.
RANDOM_STATE = 42
CUTOFF_DAY = 28
PROJECT_DIR = Path.cwd().parent if Path.cwd().name == 'notebooks' else
Path.cwd()
RUNTIME_DIR = Path('/content') if Path('/content').is_dir() else
PROJECT_DIR / 'tmp' / 'oulad_runtime'
DATA_DIR = RUNTIME_DIR / 'oulad'
print(f'Parameter eksperimen: random state {RANDOM_STATE}; horizon
observasi {CUTOFF_DAY} hari')

```

Parameter eksperimen: random state 42; horizon observasi 28 hari

2. Akuisisi Data OULAD

OULAD (*Open University Learning Analytics Dataset*) adalah dataset terbuka berisi data pembelajaran mahasiswa dari Open University. Arsip data diperoleh dari UCI Machine Learning Repository, diekstrak, lalu diverifikasi melalui tujuh tabel sumber yang diperlukan.

```

In [2]: # Lokasi dataset dan daftar file yang harus tersedia setelah ekstraksi.
DATA_URL = 'https://archive.ics.uci.edu/static/public/349/
open+university+learning+analytics+dataset.zip'
ZIP_PATH = RUNTIME_DIR / 'anonymisedData.zip'
EXPECTED_FILES = {'assessments.csv', 'courses.csv', 'studentAssessment.csv',
                  'studentInfo.csv', 'studentRegistration.csv',
                  'studentVle.csv', 'vle.csv'}

# Cek isi folder data; download hanya dilakukan jika file belum lengkap.
DATA_DIR.mkdir(parents=True, exist_ok=True)
available = {p.name for p in DATA_DIR.glob('*.csv')}
if not EXPECTED_FILES.issubset(available):
    urllib.request.urlretrieve(DATA_URL, ZIP_PATH)
    with zipfile.ZipFile(ZIP_PATH) as archive:
        archive.extractall(DATA_DIR)

```

```
# Validasi akhir memastikan seluruh file CSV sumber sudah tersedia.
available = {p.name for p in DATA_DIR.glob('*.csv')}
missing = EXPECTED_FILES - available
assert not missing, f'File dataset tidak lengkap: {sorted(missing)}'
print('Tujuh tabel sumber dimuat:', ', '.join(sorted(EXPECTED_FILES)))
```

Tujuh tabel sumber dimuat: assessments.csv, courses.csv, studentAssessment.csv, studentInfo.csv, studentRegistration.csv, studentVle.csv, vle.csv

3. Struktur Dataset

Tabel sumber mencakup `studentInfo` untuk profil dan hasil akhir, `studentRegistration` untuk tanggal registrasi, `assessments` untuk konteks modul dan penilaian, serta tabel aktivitas VLE (*Virtual Learning Environment*), yaitu platform pembelajaran daring tempat aktivitas akses mahasiswa tercatat. Ringkasan berikut menunjukkan ukuran setiap tabel, diikuti preview sumber label dan data registrasi.

```
In [3]: # Baca tabel sumber yang dipakai untuk profil, registrasi, assessment, dan
        # aktivitas VLE.
student_info = pd.read_csv(DATA_DIR / 'studentInfo.csv')
registration = pd.read_csv(DATA_DIR / 'studentRegistration.csv')
assessments = pd.read_csv(DATA_DIR / 'assessments.csv')
student_assessment = pd.read_csv(DATA_DIR / 'studentAssessment.csv')
student_vle = pd.read_csv(DATA_DIR / 'studentVle.csv')

# Ringkas ukuran tiap tabel agar struktur data awal mudah diperiksa.
source_summary = pd.DataFrame({
    'tabel': ['studentInfo', 'studentRegistration', 'assessments',
             'studentAssessment', 'studentVle'],
    'baris': [len(student_info), len(registration), len(assessments),
             len(student_assessment), len(student_vle)],
    'kolom': [student_info.shape[1], registration.shape[1],
             assessments.shape[1], student_assessment.shape[1], student_vle.shape[1]]
})
display(source_summary.style.format(thousands=','))

# Preview terpilih menunjukkan asal label hasil dan informasi registrasi.
print('Sumber label hasil akhir: studentInfo')
display(student_info[['id_student', 'code_module', 'code_presentation',
                     'final_result']].head(3))
print('Sumber informasi registrasi: studentRegistration')
display(registration[['id_student', 'code_module', 'code_presentation',
                     'date_registration', 'date_unregistration']].head(3))
```

	tabel	baris	kolom
0	studentInfo	32,593	12
1	studentRegistration	32,593	5
2	assessments	206	6
3	studentAssessment	173,912	5
4	studentVle	10,655,280	6

Sumber label hasil akhir: studentInfo

	id_student	code_module	code_presentation	final_result
0	11391	AAA	2013J	Pass
1	28400	AAA	2013J	Pass
2	30268	AAA	2013J	Withdrawn

Sumber informasi registrasi: studentRegistration

	id_student	code_module	code_presentation	date_registration	date_unregistration
0	11391	AAA	2013J	-159	?
1	28400	AAA	2013J	-53	?
2	30268	AAA	2013J	-92	12

4. Konstruksi Dataset Early Warning Minggu Ke-4

Dataset analisis dibentuk dari features yang tersedia hingga hari ke-28. Target `AtRisk` berasal dari hasil akhir, assessment difilter dengan `date_submitted <= 28`, dan aktivitas VLE difilter dengan `date <= 28`. Target adalah hasil yang diprediksi, sedangkan feature adalah informasi masukan model. Data diringkas per mahasiswa, modul, dan presentation untuk membentuk unit analisis *student-module-presentation*.

Data aktivitas OULAD memiliki informasi waktu berbasis hari relatif terhadap awal course. Notebook menggunakan data harian tersebut sebagai sumber, lalu merangkumnya menjadi aggregated features minggu ke-4 seperti total klik VLE, jumlah hari aktif, jumlah assessment, dan mean score assessment.

`final_result` membentuk label supervised learning. Model belajar dari data awal minggu ke-4 untuk memprediksi kelas akhir, sedangkan daftar prediktor berisi informasi yang tersedia sampai hari ke-28.

Mahasiswa dengan status akhir `Withdrawn` tetap menjadi bagian dari label `AtRisk` karena tujuan model adalah mengenali pola awal yang berkaitan dengan risiko tersebut. Interpretasi hasil berfokus pada sinyal yang tersedia sampai hari ke-28.

Jejak konstruksi berikut memperlihatkan baris assessment dan VLE setelah filter hari ke-28, aggregated features, serta dataset analisis yang terbentuk.

```
In [4]: KEYS = ['code_module', 'code_presentation', 'id_student']

# Target biner berasal dari hasil akhir; ini label supervised learning,
# bukan fitur prediksi.
# Fitur prediktor tetap dibatasi pada data yang tersedia sampai hari ke-28.
base = student_info.copy()
base['risk_label'] = np.where(base['final_result'].isin(['Withdrawn',
'Fail']), 'AtRisk', 'Successful')

# Fitur registrasi yang tersedia sebelum/awal perkuliahan; unregistration
# sengaja dikeluarkan.
# date_unregistration bersifat post-hoc sehingga berisiko leakage untuk
```

```

early warning minggu ke-4.
reg_features = registration[KEYS + ['date_registration']].copy()

# Hubungkan submission ke konteks module-presentation, lalu batasi sampai
hari ke-28.
student_assessment['date_submitted'] =
pd.to_numeric(student_assessment['date_submitted'], errors='coerce')
student_assessment['score'] = pd.to_numeric(student_assessment['score'],
errors='coerce')
assessment_early = student_assessment.merge(
    assessments[['id_assessment', 'code_module', 'code_presentation']],
    on='id_assessment', how='left'
)
assessment_early = assessment_early[assessment_early['date_submitted'] <=
CUTOFF_DAY]
assessment_features = (assessment_early.groupby(KEYS)
    .agg(assessment_count=('id_assessment', 'count'),
        assessment_score_mean=('score', 'mean'),
        assessment_score_max=('score', 'max'),
        assessment_score_min=('score', 'min'))
    .reset_index())

# Aktivitas VLE juga dibatasi sampai hari ke-28.
student_vle['date'] = pd.to_numeric(student_vle['date'], errors='coerce')
student_vle['sum_click'] = pd.to_numeric(student_vle['sum_click'],
errors='coerce').fillna(0)
vle_early = student_vle[student_vle['date'] <= CUTOFF_DAY].copy()
vle_features = (vle_early.groupby(KEYS)
    .agg(vle_total_clicks=('sum_click', 'sum'),
        vle_active_days=('date', 'nunique'),
        vle_site_count=('id_site', 'nunique'),
        vle_last_activity_day=('date', 'max'))
    .reset_index())

dataset = (base.merge(reg_features, on=KEYS, how='left')
    .merge(assessment_features, on=KEYS, how='left')
    .merge(vle_features, on=KEYS, how='left'))

behavior_cols = ['assessment_count', 'assessment_score_mean',
'assessment_score_max',
                'assessment_score_min', 'vle_total_clicks',
'vle_active_days',
                'vle_site_count', 'vle_last_activity_day']
dataset[behavior_cols] = dataset[behavior_cols].fillna(0)

# Jejak observasi hingga hari ke-28 dan fitur hasil agregasi.
print('Assessment yang tersedia hingga hari ke-28')
display(assessment_early[['id_student', 'code_module', 'code_presentation',
                        'date_submitted', 'score']].head(3))
print('Assessment features per student-module-presentation')
assessment_preview = assessment_features.rename(columns={
    'code_module': 'Modul', 'code_presentation': 'Presentasi',
    'id_student': 'Mahasiswa',
    'assessment_count': 'Assessment count', 'assessment_score_mean': 'Mean
score',
    'assessment_score_max': 'Maximum score', 'assessment_score_min':
'Minimum score'
})
display(assessment_preview.head(3))
print('Aktivitas VLE yang tersedia hingga hari ke-28')

```

```

display(vle_early[['id_student', 'date', 'id_site', 'sum_click']].head(3))
print('VLE features per student-module-presentation')
vle_preview = vle_features.rename(columns={
    'code_module': 'Modul', 'code_presentation': 'Presentasi',
    'id_student': 'Mahasiswa',
    'vle_total_clicks': 'Total VLE clicks', 'vle_active_days': 'Active VLE
days',
    'vle_site_count': 'VLE site count', 'vle_last_activity_day': 'Last
activity day'
})
display(vle_preview.head(3))

print(f'Unit analisis: {len(dataset):,} student-module-presentation')
print(f'Mahasiswa unik: {dataset.id_student.nunique():,}')
analysis_columns = (KEYS + ['final_result', 'risk_label',
    'date_registration',
    'assessment_count', 'assessment_score_mean',
    'vle_total_clicks', 'vle_active_days'])
print('Analysis dataset setelah merging dan aggregation')
analysis_preview = dataset[analysis_columns].rename(columns={
    'code_module': 'Modul', 'code_presentation': 'Presentasi',
    'id_student': 'Mahasiswa',
    'final_result': 'Final result', 'risk_label': 'Risk label',
    'date_registration': 'Registration day', 'assessment_count':
    'Assessment count',
    'assessment_score_mean': 'Mean score', 'vle_total_clicks': 'Total VLE
clicks',
    'vle_active_days': 'Active VLE days'
})
display(analysis_preview.head(5))

```

Assessment yang tersedia hingga hari ke-28

	id_student	code_module	code_presentation	date_submitted	score
0	11391	AAA	2013J	18	78.0
1	28400	AAA	2013J	22	70.0
2	31604	AAA	2013J	17	72.0

Assessment features per student-module-presentation

	Modul	Presentasi	Mahasiswa	Assessment count	Mean score	Maximum score	Minimum score
0	AAA	2013J	11391	1	78.0	78.0	78.0
1	AAA	2013J	28400	1	70.0	70.0	70.0
2	AAA	2013J	31604	1	72.0	72.0	72.0

Aktivitas VLE yang tersedia hingga hari ke-28

	id_student	date	id_site	sum_click
0	28400	-10	546652	4
1	28400	-10	546652	1
2	28400	-10	546652	1

VLE features per student-module-presentation

	Modul	Presentasi	Mahasiswa	Total VLE clicks	Active VLE days	VLE site count	Last activity day
0	AAA	2013J	11391	401	8	24	18
1	AAA	2013J	28400	618	19	34	28
2	AAA	2013J	30268	281	12	22	12

Unit analisis: 32,593 student-module-presentation

Mahasiswa unik: 28,785

Analysis dataset setelah merging dan aggregation

	Modul	Prese ntasi	Mahas iswa	Final result	Risk label	Regist ration day	Asses sment count	Mean score	Total VLE clicks	Active VLE days
0	AAA	2013J	11391	Pass	Succe ssful	-159	1.0	78.0	401.0	8.0
1	AAA	2013J	28400	Pass	Succe ssful	-53	1.0	70.0	618.0	19.0
2	AAA	2013J	30268	Withdr awn	AtRisk	-92	0.0	0.0	281.0	12.0
3	AAA	2013J	31604	Pass	Succe ssful	-52	1.0	72.0	494.0	22.0
4	AAA	2013J	32885	Pass	Succe ssful	-176	1.0	69.0	567.0	24.0

5. Prediction Horizon Validation

Prediction horizon menetapkan informasi yang tersedia saat prediksi dibuat. Pada penelitian ini, seluruh predictors dibentuk dari observasi hingga hari ke-28. Validasi ini menjaga *data leakage*, yaitu masuknya informasi masa depan ke dalam proses prediksi. Daftar predictors mencakup data demografis, registrasi awal, assessment awal, dan aktivitas VLE awal.

Tipe data yang digunakan:

Jenis data	Contoh kolom	Peran dalam notebook
Categorical features	gender , region , imd_band , code_module	Features yang diproses dengan one-hot encoding, yaitu mengubah setiap kategori menjadi penanda 0/1
Numerical features	studied_credits , assessment_count , vle_total_clicks	Features yang diimputasi, yaitu diisi bila terdapat missing values, lalu distandardisasi agar skalanya sebanding
Temporal	date_submitted , date , date_registration	Dasar cut-off early warning sampai hari ke-28
Target label	risk_label	Output klasifikasi biner
Identitas grouping	id_student	Grup untuk train-test split dan cross-validation, yaitu evaluasi berulang pada beberapa pembagian data
Kolom referensi hasil akhir	final_result	Sumber pembentukan label supervised learning

Jenis data	Contoh kolom	Peran dalam notebook
Informasi setelah kejadian	<code>date_unregistration</code>	Dikeluarkan dari daftar prediktor untuk menjaga informasi prediksi tetap tersedia pada minggu ke-4

Daftar features berikut mendefinisikan *feature matrix* sebagai input model.

```
In [5]: # Pisahkan fitur kategorikal dan numerik untuk preprocessing yang berbeda.
CATEGORICAL_COLS = ['gender', 'region', 'highest_education', 'imd_band',
                    'age_band', 'disability', 'code_module',
                    'code_presentation']
NUMERIC_COLS = ['num_of_prev_attempts', 'studied_credits',
                'date_registration',
                'assessment_count', 'assessment_score_mean',
                'assessment_score_max',
                'assessment_score_min', 'vle_total_clicks',
                'vle_active_days',
                'vle_site_count', 'vle_last_activity_day']
FEATURE_COLS = CATEGORICAL_COLS + NUMERIC_COLS
# Kolom berikut tidak boleh menjadi prediktor karena berisi target atau
# informasi post-hoc.
FORBIDDEN = {'final_result', 'risk_label', 'date_unregistration',
             'has_unregistration'}

# Validasi anti-leakage: fitur model harus bebas dari target dan data
# setelah hari ke-28.
assert not FORBIDDEN.intersection(FEATURE_COLS)
assert vle_early['date'].max() <= CUTOFF_DAY
assert assessment_early['date_submitted'].max() <= CUTOFF_DAY
print('Prediction horizon: features dibentuk dari observasi hingga hari
ke-28.')
print('Categorical features:', CATEGORICAL_COLS)
print('Numerical features:', NUMERIC_COLS)
```

Prediction horizon: features dibentuk dari observasi hingga hari ke-28.

Categorical features: ['gender', 'region', 'highest_education', 'imd_band', 'age_band', 'disability', 'code_module', 'code_presentation']

Numerical features: ['num_of_prev_attempts', 'studied_credits', 'date_registration', 'assessment_count', 'assessment_score_mean', 'assessment_score_max', 'assessment_score_min', 'vle_total_clicks', 'vle_active_days', 'vle_site_count', 'vle_last_activity_day']

6. Eksplorasi Data

Exploratory Data Analysis (EDA) memeriksa distribusi, kelengkapan, dan pola awal data sebelum pemodelan. Visualisasi berikut membandingkan distribusi target, missing values, serta median assessment dan aktivitas VLE pada kelas `AtRisk` dan `Successful`.

```
In [6]: # Hitung missing value, distribusi target, dan median perilaku awal per
# kelas.
missing_summary =
dataset[FEATURE_COLS].isna().sum().sort_values(ascending=False)
class_counts = dataset['risk_label'].value_counts()
behavior_by_class = dataset.groupby('risk_label')[
    ['assessment_count', 'assessment_score_mean', 'vle_total_clicks',
    'vle_active_days']]
```

```

].median().round(2)

# Tampilkan distribusi kelas dan kondisi missing value sebagai ringkasan EDA awal.
fig, axes = plt.subplots(1, 2, figsize=(14, 4))
sns.countplot(data=dataset, x='risk_label', order=['Successful', 'AtRisk'],
ax=axes[0])
axes[0].set_title('Target Distribution')
axes[0].set_xlabel('Kelas'); axes[0].set_ylabel('Jumlah')
missing_nonzero = missing_summary[missing_summary > 0]
if missing_nonzero.empty:
    axes[1].text(0.5, 0.55, 'Missing values pada features analisis: 0',
ha='center', va='center',
                fontsize=18, fontweight='bold', color='#2A9D8F')
    axes[1].text(0.5, 0.40, 'Pemeriksaan dilakukan sebelum preprocessing',
ha='center', va='center')
    axes[1].set_axis_off()
else:
    missing_nonzero.plot(kind='bar', ax=axes[1], color='#E9C46A')
    axes[1].set_title('Missing Values by Feature')
    axes[1].set_xlabel('Fitur'); axes[1].set_ylabel('Jumlah')
plt.tight_layout(); plt.show()
# Tabel median membantu membandingkan perilaku minggu ke-4 antara kelas risiko.
display(behavior_by_class)
print(class_counts)

```



Missing values pada features analisis: 0

Pemeriksaan dilakukan sebelum preprocessing

	assessment_count	assessment_score_mean	vle_total_clicks	vle_active_days
risk_label				
AtRisk	1.0	0.0	92.0	7.0
Successful	1.0	76.0	298.0	16.0

```

risk_label
AtRisk      17208
Successful  15385
Name: count, dtype: int64


```

7. Data Split Design

Hold-out test adalah bagian data yang disisihkan sejak awal untuk mengukur kemampuan model pada data baru. *Data split* membagi data menjadi 80% train-validation dan 20% test menggunakan `id_student` sebagai grup melalui `GroupShuffleSplit`. Seluruh baris dari mahasiswa yang sama berada pada satu bagian data.

Train-validation dievaluasi menggunakan `GroupKFold`. *Fold* adalah satu bagian dari pembagian data dan bergantian menjadi validation, yaitu data untuk memeriksa model saat pelatihan. Ukuran split dan overlap mahasiswa diringkas pada output berikut.

Skema evaluasi dan pemisahan data



`id_student` digunakan sebagai grup sehingga setiap mahasiswa berada pada satu bagian data dan overlap bernilai nol. Lima fold digunakan pada bagian train-validation untuk memilih model. Hold-out test digunakan setelah model terpilih untuk mengukur generalisasi pada data baru.

```
In [7]: # Pastikan seluruh fitur numerik siap diproses oleh pipeline model.
for column in NUMERIC_COLS:
    dataset[column] = pd.to_numeric(dataset[column], errors='coerce')

# Bentuk matriks fitur, target biner, dan grup mahasiswa untuk split
# berbasis id_student.
# Karena unit analisis adalah student-module-presentation, satu mahasiswa
# bisa muncul lebih dari sekali.
X = dataset[FEATURE_COLS].copy()
y = dataset['risk_label'].map({'Successful': 0, 'AtRisk': 1})
groups = dataset['id_student']
print('Feature matrix: tiga student-module-presentation pertama')
display(X.head(3).T.rename(columns={0: 'Sampel 1', 1: 'Sampel 2', 2:
'Sampel 3'}))

# Split 80:20 berbasis mahasiswa agar id_student yang sama tidak muncul di
# train dan test.
# Validation set statis tidak dibuat karena train-validation akan dievaluasi
# dengan GroupKFold.
splitter = GroupShuffleSplit(n_splits=1, test_size=0.20,
random_state=RANDOM_STATE)
train_idx, test_idx = next(splitter.split(X, y, groups))
X_train, X_test = X.iloc[train_idx].copy(), X.iloc[test_idx].copy()
y_train, y_test = y.iloc[train_idx].copy(), y.iloc[test_idx].copy()
groups_train = groups.iloc[train_idx].copy()

# Cek overlap mahasiswa sebagai validasi bahwa split berbasis grup berhasil.
train_students = set(groups.iloc[train_idx])
test_students = set(groups.iloc[test_idx])
overlap = train_students.intersection(test_students)
assert len(overlap) == 0
print(f'Train-validation: {len(X_train):,} baris | Test: {len(X_test):,}
baris')
```

```
print(f'Overlap mahasiswa: {len(overlap)}')
print('Distribusi train:',
y_train.value_counts(normalize=True).round(3).to_dict())
print('Distribusi test :',
y_test.value_counts(normalize=True).round(3).to_dict())
```

Feature matrix: tiga student-module-presentation pertama

	Sampel 1	Sampel 2	Sampel 3
gender	M	F	F
region	East Anglian Region	Scotland	North Western Region
highest_education	HE Qualification	HE Qualification	A Level or Equivalent
imd_band	90-100%	20-30%	30-40%
age_band	55<=	35-55	35-55
disability	N	N	Y
code_module	AAA	AAA	AAA
code_presentation	2013J	2013J	2013J
num_of_prev_attempts	0	0	0
studied_credits	240	60	60
date_registration	-159.0	-53.0	-92.0
assessment_count	1.0	1.0	0.0
assessment_score_mean	78.0	70.0	0.0
assessment_score_max	78.0	70.0	0.0
assessment_score_min	78.0	70.0	0.0
vle_total_clicks	401.0	618.0	281.0
vle_active_days	8.0	19.0	12.0
vle_site_count	24.0	34.0	22.0
vle_last_activity_day	18.0	28.0	12.0

Train-validation: 26,122 baris | Test: 6,471 baris

Overlap mahasiswa: 0

Distribusi train: {1: 0.529, 0: 0.471}

Distribusi test : {1: 0.525, 0: 0.475}

8. Pipeline Preprocessing dan Model

Preprocessing menyiapkan format dan nilai data untuk pemodelan. Numerical features diimputasi dengan median dan distandardisasi; categorical features diimputasi lalu diubah dengan one-hot encoding menjadi representasi 0/1. Seluruh transformasi berada di dalam pipeline sehingga parameter preprocessing dipelajari dari training data pada setiap fold.

Logistic Regression, Random Forest, dan XGBoost digunakan sebagai baseline, yaitu pembandingan awal dengan konfigurasi yang konsisten. Hyperparameter, yaitu pengaturan model yang ditentukan sebelum pelatihan, dibuat tetap selama evaluasi agar perbandingan

antar model mudah dibaca; tuning lanjutan dapat dilakukan setelah baseline terbaik ditentukan.

Tiga model pembandingan yang digunakan adalah Logistic Regression, Random Forest, dan XGBoost.

Ringkasan preprocessing

Komponen	Perlakuan	Tujuan
Missing values pada numerical features	Median imputation	Menjaga baris tetap dapat diproses tanpa dipengaruhi nilai ekstrem.
Missing values pada categorical features	Most-frequent imputation	Menyediakan nilai yang konsisten sebelum encoding.
Categorical features	One-hot encoding	Mengubah kategori menjadi representasi numerik untuk model.
Numerical features	Standardization	Menyamakan skala untuk model yang sensitif terhadap besaran feature.
Class imbalance	<code>class_weight</code> atau <code>scale_pos_weight</code>	Memberi perhatian lebih besar pada kelas <code>AtRisk</code> tanpa membuat data sintetis.

Seluruh imputasi, encoding, dan standardisasi berada di dalam pipeline. Pada setiap fold, parameter preprocessing dipelajari dari training data fold tersebut. Class imbalance ditangani dengan `class_weight` atau `scale_pos_weight`, sementara distribusi kelas dan seluruh metrik ditampilkan agar trade-off prediksi dapat dibaca secara terbuka.

```
In [8]: # Numerical features diimputasi lalu distandardisasi.
numeric_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler())
])
# Categorical features diimputasi lalu diubah menjadi one-hot encoding.
categorical_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])
# ColumnTransformer menerapkan pipeline sesuai tipe fitur.
preprocessor = ColumnTransformer([
    ('numeric', numeric_pipe, NUMERIC_COLS),
    ('categorical', categorical_pipe, CATEGORICAL_COLS)
])

# Bobot kelas membantu model memberi perhatian pada kelas AtRisk.
negative, positive = np.bincount(y_train)
scale_pos_weight = negative / positive
# Tiga model dibandingkan dengan konfigurasi yang konsisten.
models = {
    'Logistic Regression': LogisticRegression(max_iter=1500,
class_weight='balanced', random_state=RANDOM_STATE),
    'Random Forest': RandomForestClassifier(n_estimators=250,
class_weight='balanced',
random_state=RANDOM_STATE,
```

```

n_jobs=-1),
    'XGBoost': XGBClassifier(n_estimators=200, max_depth=4,
learning_rate=0.08,
                                subsample=0.9, colsample_bytree=0.9,
                                scale_pos_weight=scale_pos_weight,
eval_metric='logloss',
                                random_state=RANDOM_STATE, n_jobs=-1)
}
# Gabungkan preprocessing dan model agar transformasi hanya belajar dari
data train.
pipelines = {name: Pipeline([('preprocess', clone(preprocessor)), ('model',
model)])
                for name, model in models.items()}
print('Model pembanding:', ', '.join(pipelines))

```

Model pembanding: Logistic Regression, Random Forest, XGBoost

9. Model Selection with Cross-Validation

Cross-validation mengevaluasi model secara berulang pada beberapa pembagian train dan validation. Tiga model dievaluasi dengan lima fold berbasis kelompok mahasiswa. Recall **AtRisk** menjadi metrik seleksi utama; F1 digunakan sebagai tie-breaker bila recall sama.

Alasan metrik: recall **AtRisk** diprioritaskan karena konteks early warning berfokus menangkap sebanyak mungkin mahasiswa berisiko. Precision, yaitu proporsi prediksi **AtRisk** yang benar, menunjukkan kualitas alarm. False positive menggambarkan alarm **AtRisk** pada mahasiswa **Successful** dan membantu membaca beban intervensi. Accuracy menunjukkan proporsi seluruh prediksi yang benar, sedangkan ROC-AUC menunjukkan kemampuan model membedakan dua kelas pada berbagai threshold.

Alasan 5-fold: lima fold memberi keseimbangan antara estimasi performa yang stabil dan biaya komputasi yang wajar untuk tiga model pembanding. Karena split menggunakan **GroupKFold**, prioritas evaluasi adalah menjaga mahasiswa yang sama berada dalam grup fold yang konsisten.

GroupKFold memprioritaskan pemisahan berdasarkan mahasiswa. Konsistensi performa antar fold dibaca melalui mean, yaitu rata-rata, dan standard deviation, yaitu ukuran variasi hasil antar fold. Standard deviation yang kecil menunjukkan hasil model relatif stabil pada beberapa pembagian train-validation.

Tabel berikut menampilkan mean dan standard deviation untuk accuracy, precision, recall, F1, dan ROC-AUC pada lima fold.

In [9]:

```

# Fungsi ini menyatukan metrik yang dipakai berulang pada CV dan hold-out
test.
def calculate_metrics(y_true, y_pred, y_prob):
    return {
        'accuracy': accuracy_score(y_true, y_pred),
        'precision_atrisk': precision_score(y_true, y_pred,
zero_division=0),
        'recall_atrisk': recall_score(y_true, y_pred, zero_division=0),
        'f1_atrisk': f1_score(y_true, y_pred, zero_division=0),
        'roc_auc': roc_auc_score(y_true, y_prob)
    }

```

```

# GroupKFold menjaga mahasiswa yang sama tetap berada dalam fold yang sama.
# Setiap fold bergantian menjadi validation, sehingga tidak perlu validation
split statis.
gkf = GroupKFold(n_splits=5)
cv_rows = []
for model_name, pipeline in pipelines.items():
    for fold, (fit_idx, val_idx) in enumerate(gkf.split(X_train, y_train,
groups_train), start=1):
        fold_model = clone(pipeline)
        fold_model.fit(X_train.iloc[fit_idx], y_train.iloc[fit_idx])
        pred = fold_model.predict(X_train.iloc[val_idx])
        prob = fold_model.predict_proba(X_train.iloc[val_idx])[:, 1]
        cv_rows.append({'model': model_name, 'fold': fold,
                        **calculate_metrics(y_train.iloc[val_idx], pred,
prob)})

# Ringkas hasil tiap fold menjadi rata-rata dan standar deviasi per model.
cv_detail = pd.DataFrame(cv_rows)
cv_summary = cv_detail.groupby('model').agg(
    accuracy_mean=('accuracy', 'mean'), accuracy_std=('accuracy', 'std'),
    precision_mean=('precision_atrisk', 'mean'),
    precision_std=('precision_atrisk', 'std'),
    recall_mean=('recall_atrisk', 'mean'), recall_std=('recall_atrisk',
'std'),
    f1_mean=('f1_atrisk', 'mean'), f1_std=('f1_atrisk', 'std'),
    roc_auc_mean=('roc_auc', 'mean'), roc_auc_std=('roc_auc', 'std')
).sort_values(['recall_mean', 'f1_mean'], ascending=False)
display(cv_summary.style.format('{:.4f}').highlight_max(subset=['recall_mean',
'f1_mean'], color='#B7E4C7'))

```

	accuracy_mean	accuracy_std	precision_mean	precision_std	recall_mean	recall_std	f1_mean	f1_std	roc_auc_mean	roc_auc_std
model										
Random Forest	0.7524	0.0013	0.7989	0.0136	0.7107	0.0085	0.7521	0.0030	0.8362	0.0023
XGBoost	0.7584	0.0024	0.8215	0.0096	0.6938	0.0029	0.7522	0.0039	0.8440	0.0019
Logistic Regression	0.7496	0.0039	0.8090	0.0059	0.6889	0.0064	0.7442	0.0059	0.8330	0.0027

10. Evaluasi Generalisasi pada Hold-Out Test

Generalisasi adalah kemampuan model mempertahankan performa pada data di luar proses pelatihan. Model dipilih dari hasil cross-validation berdasarkan recall dan F1 AtRisk, kemudian dilatih pada seluruh train-validation. Hold-out test memberikan evaluasi generalisasi akhir dan perbandingan model.

Peringkat cv_summary pada lima fold train-validation menentukan model final. Hold-out test kemudian memberikan evaluasi generalisasi akhir. Random Forest dipilih ketika memberikan recall AtRisk tertinggi, sesuai tujuan utama early warning.

Tabel metrik dan classification report berikut merangkum performa model final pada hold-out test.

```
In [10]: # Latih ulang setiap model pada seluruh train-validation, lalu prediksi
hold-out test.
fitted_models, test_predictions, test_probabilities, test_rows = {}, {},
{}, []
for model_name, pipeline in pipelines.items():
    fitted = clone(pipeline).fit(X_train, y_train)
    pred = fitted.predict(X_test)
    prob = fitted.predict_proba(X_test)[:, 1]
    fitted_models[model_name] = fitted
    test_predictions[model_name] = pred
    test_probabilities[model_name] = prob
    test_rows.append({'model': model_name, **calculate_metrics(y_test,
pred, prob)})

# Urutkan hasil test berdasarkan recall AtRisk dan F1.
test_results = pd.DataFrame(test_rows).set_index('model').sort_values(
    ['recall_atrisk', 'f1_atrisk'], ascending=False)
# Model terbaik mengikuti peringkat cross-validation agar pemilihan tidak
memakai test set.
# Test set hanya menjadi pelaporan generalisasi akhir, bukan dasar tuning
atau seleksi model.
best_model_name = cv_summary.index[0]
best_model = fitted_models[best_model_name]
best_pred = test_predictions[best_model_name]
best_prob = test_probabilities[best_model_name]

# Tampilkan tabel metrik dan classification report untuk model terbaik.
display(test_results.style.format('{:.4f}').highlight_max(subset=['recall_atr:
'f1_atrisk'], color='#B7E4C7'))
print(f'Model terpilih berdasarkan cross-validation: {best_model_name}')
print(classification_report(y_test, best_pred, target_names=['Successful',
'AtRisk']))
```

	accuracy	precision_atrisk	recall_atrisk	f1_atrisk	roc_auc
model					
Random Forest	0.7594	0.8007	0.7213	0.7589	0.8396
XGBoost	0.7611	0.8154	0.7045	0.7559	0.8443
Logistic Regression	0.7487	0.8034	0.6904	0.7426	0.8311

Model terpilih berdasarkan cross-validation: Random Forest

	precision	recall	f1-score	support
Successful	0.72	0.80	0.76	3073
AtRisk	0.80	0.72	0.76	3398
accuracy			0.76	6471
macro avg	0.76	0.76	0.76	6471
weighted avg	0.76	0.76	0.76	6471

Benchmark angka dengan penelitian sebelumnya

Bagian ini menyandingkan hasil model terbaik notebook dengan angka performa yang dilaporkan oleh beberapa penelitian sebelumnya. Metrik kosong menunjukkan bahwa paper tersebut tidak melaporkan metrik yang sama.

Tabel dan grafik ini digunakan sebagai konteks benchmark, yaitu pembandingan dengan hasil penelitian sebelumnya. Evaluasi utama tetap mengacu pada hasil OULAD dengan cut-off hari ke-28, sedangkan perbedaan dataset, target, horizon prediksi, desain split, dan metrik menjadi konteks pembacaan. Tanda  menunjukkan metrik yang tidak dilaporkan oleh penelitian terkait.

```
In [11]: # Benchmark angka dari paper terdahulu dan hasil model terbaik notebook.
benchmark_metrics = pd.DataFrame([
    {
        'Sumber': 'Matz et al. (2023)',
        'Skenario': 'Retention/dropout + engagement',
        'Model': 'Random Forest',
        'Accuracy': np.nan,
        'Precision': np.nan,
        'Recall': np.nan,
        'F1-score': np.nan,
        'ROC-AUC': 0.88
    },
    {
        'Sumber': 'Carballo-Mendivil et al. (2025)',
        'Skenario': 'Early warning pre-enrollment',
        'Model': 'XGBoost',
        'Accuracy': np.nan,
        'Precision': 0.57,
        'Recall': 0.88,
        'F1-score': 0.69,
        'ROC-AUC': 0.6902
    },
    {
        'Sumber': 'Martins et al. (2023)',
        'Skenario': 'Phased prediction',
        'Model': 'Random Forest / ML',
        'Accuracy': np.nan,
        'Precision': np.nan,
        'Recall': np.nan,
        'F1-score': 0.745,
        'ROC-AUC': np.nan
    },
    {
        'Sumber': 'Notebook ini',
        'Skenario': 'OULAD minggu ke-4',
        'Model': best_model_name,
        'Accuracy': test_results.loc[best_model_name, 'accuracy'],
        'Precision': test_results.loc[best_model_name, 'precision_atrisk'],
        'Recall': test_results.loc[best_model_name, 'recall_atrisk'],
        'F1-score': test_results.loc[best_model_name, 'f1_atrisk'],
        'ROC-AUC': test_results.loc[best_model_name, 'roc_auc']
    }
])
```

```


display(benchmark_metrics.style.format({
    'Accuracy': '{:.4f}',
    'Precision': '{:.4f}',
    'Recall': '{:.4f}',
    'F1-score': '{:.4f}',
    'ROC-AUC': '{:.4f}'
}, na_rep='-'))

benchmark_long = benchmark_metrics.melt(
    id_vars=['Sumber', 'Skenario', 'Model'],
    value_vars=['Accuracy', 'Precision', 'Recall', 'F1-score', 'ROC-AUC'],
    var_name='Metrik',
    value_name='Nilai'
).dropna()

plt.figure(figsize=(12, 6))
sns.barplot(data=benchmark_long, y='Metrik', x='Nilai', hue='Sumber')
plt.xlim(0, 1)
plt.title('Benchmark Metrik Model dengan Penelitian Sebelumnya')
plt.xlabel('Nilai metrik')
plt.ylabel('')
plt.legend(title='Sumber', bbox_to_anchor=(1.02, 1), loc='upper left')
plt.tight_layout()
plt.show()

```

	Sumber	Skenario	Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
0	Matz et al. (2023)	Retention/dropout + engagement	Random Forest	-	-	-	-	0.8800
1	Carballo-Mendivil et al. (2025)	Early warning pre-enrollment	XGBoost	-	0.5700	0.8800	0.6900	0.6902
2	Martins et al. (2023)	Phased prediction	Random Forest / ML	-	-	-	0.7450	-
3	Notebook ini	OULAD minggu ke-4	Random Forest	0.7594	0.8007	0.7213	0.7589	0.8396




11. Visualisasi Evaluasi Model

Visualisasi berikut membandingkan metrik, confusion matrix, dan ROC curve. *Confusion matrix* merangkum prediksi benar serta salah untuk setiap kelas, sedangkan ROC curve menunjukkan kemampuan pemisahan kelas pada berbagai threshold keputusan. False negative menunjukkan mahasiswa `AtRisk` yang diprediksi `Successful`.

```
In [12]: # Siapkan tiga panel visual: perbandingan metrik, confusion matrix, dan ROC
curve.
fig, axes = plt.subplots(1, 3, figsize=(20, 5))
test_results[['precision_atrisk', 'recall_atrisk',
'f1_atrisk']].plot(kind='bar', ax=axes[0])
axes[0].set_title('Perbandingan Metrik AtRisk'); axes[0].set_ylim(0, 1);
axes[0].tick_params(axis='x', rotation=15)

# Confusion matrix menunjukkan kombinasi prediksi benar dan salah untuk
model terbaik.
cm_best = confusion_matrix(y_test, best_pred)
sns.heatmap(cm_best, annot=True, fmt='d', cmap='Blues', ax=axes[1],
            xticklabels=['Successful', 'AtRisk'],
            yticklabels=['Successful', 'AtRisk'])
axes[1].set_title(f'Confusion Matrix - {best_model_name}')
axes[1].set_xlabel('Prediksi'); axes[1].set_ylabel('Aktual')

# ROC curve membandingkan kemampuan pemeringkatan risiko dari setiap model.
for name, prob in test_probabilities.items():
    fpr, tpr, _ = roc_curve(y_test, prob)
    axes[2].plot(fpr, tpr, label=f'{name} (AUC={roc_auc_score(y_test,
prob):.3f})')
axes[2].plot([0, 1], [0, 1], '--', color='gray')
axes[2].set_title('ROC Curve'); axes[2].set_xlabel('False Positive Rate');
axes[2].set_ylabel('True Positive Rate')
axes[2].legend(fontsize=8)
plt.tight_layout(); plt.show()
```



12. Feature Importance of the Final Model


Feature importance menunjukkan kontribusi setiap feature pada prediksi model. Untuk model pohon, nilai ini berasal dari `feature_importances_`; untuk Logistic Regression, kontribusi dibaca dari nilai absolut coefficient.

Interpretasi: feature importance menunjukkan kontribusi prediktif global di dalam model. Analisis hubungan sebab-akibat memerlukan rancangan penelitian kausal. Alasan pada daftar prioritas berasal dari rule-based risk layer dan diterjemahkan menjadi tindak lanjut operasional.

Grafik berikut menampilkan top 15 features dengan kontribusi prediktif terbesar.

```
In [13]: # Ambil nama fitur setelah preprocessing agar importance cocok dengan kolom
         # hasil encoding.
         feature_names = best_model.named_steps['preprocess'].get_feature_names_out()
         estimator = best_model.named_steps['model']
         # Model pohon memakai feature_importances_; Logistic Regression memakai
         # absolut koefisien.
         if hasattr(estimator, 'feature_importances_'):
             importance_values = estimator.feature_importances_
             importance_label = 'Feature importance'
         else:
             importance_values = np.abs(estimator.coef_[0])
             importance_label = 'Absolute coefficient'

         # Urutkan 15 fitur teratas untuk visualisasi interpretasi model.
         feature_importance = (pd.DataFrame({'feature': feature_names, 'importance':
             importance_values})
                               .sort_values('importance', ascending=False).head(15))
         plt.figure(figsize=(10, 6))
         sns.barplot(data=feature_importance, x='importance', y='feature',
             color='#2A9D8F')
         plt.title(f'Top 15 Features - {best_model_name}')
         plt.xlabel(importance_label); plt.ylabel(''); plt.tight_layout(); plt.show()
         display(feature_importance)
```



	feature	importance
7	numeric__vle_total_clicks	0.099771
10	numeric__vle_last_activity_day	0.090496
8	numeric__vle_active_days	0.083878
9	numeric__vle_site_count	0.078905
2	numeric__date_registration	0.064367
6	numeric__assessment_score_min	0.062229
4	numeric__assessment_score_mean	0.062033
5	numeric__assessment_score_max	0.056934
1	numeric__studied_credits	0.034319
3	numeric__assessment_count	0.018800
53	categorical__code_module_GGG	0.016933
28	categorical__highest_education_Lower Than A Level	0.012606
0	numeric__num_of_prev_attempts	0.011444
52	categorical__code_module_FFF	0.010675
50	categorical__code_module_DDD	0.010673

13. Knowledge-Based Risk Layer

Knowledge-based risk layer menerjemahkan prediksi model menjadi kategori risiko, skor probabilitas, alasan, dan rekomendasi tindak lanjut. Threshold perilaku dihitung dari kuartil bawah data train, yaitu batas 25% nilai terendah. Probabilitas `AtRisk`, prediksi model, dan jumlah sinyal perilaku membentuk kategori `High`, `Medium`, atau `Low Risk`.

Level risiko menggunakan rule-based grouping, yaitu pengelompokan berdasarkan aturan yang telah ditentukan, untuk decision support setelah model klasifikasi biner menghasilkan prediksi `AtRisk` atau `Successful`.

Makna probabilitas: `probability_atrisk` adalah $P(\text{AtRisk})$, yaitu probabilitas kelas positif `AtRisk` yang dihasilkan model melalui `predict_proba(...)[ :, 1]`. Prediksi kelas biner berasal dari `predict`. Nilai ini digunakan sebagai probabilitas risiko model untuk prioritas. Kalibrasi probabilitas, yaitu penyesuaian agar nilai probabilitas mendekati frekuensi kejadian sebenarnya, dan tuning threshold keputusan menjadi pengembangan berikutnya.

Aturan: High = model `AtRisk` dan minimal dua sinyal; Medium = model `AtRisk` atau minimal dua sinyal; selain itu Low.

Alasan dua sinyal: minimal dua sinyal perilaku digunakan untuk membuat kategori `High Risk` lebih kuat secara operasional. Kombinasi prediksi model dan beberapa indikator rendah membantu menyusun prioritas intervensi yang lebih terarah.

Kuartil bawah digunakan sebagai baseline berbasis distribusi train. Nilai ini belum menjadi kebijakan final institusi dan perlu divalidasi bersama dosen, tutor, atau pengelola akademik sebelum dipakai untuk intervensi nyata.

Threshold, distribusi level risiko, probabilitas, alasan, dan rekomendasi disajikan pada output berikut.

```
In [14]: # Threshold aturan dihitung dari kuartil bawah data train agar tidak mengambil
informasi test.
# Nilai threshold ini adalah baseline knowledge rule dan perlu validasi pakar
akademik.
RULE_COLS = ['assessment_score_mean', 'assessment_count', 'vle_total_clicks',
'vle_active_days']
thresholds = X_train[RULE_COLS].quantile(0.25).to_dict()

# Fungsi ini menambahkan prediksi ML, sinyal aturan, level risiko, dan
rekomendasi.
def add_knowledge_layer(frame, ml_pred, ml_prob, thresholds):
    result = frame.copy()
    result['predicted_atrisk'] = np.asarray(ml_pred).astype(int)
    result['probability_atrisk'] = np.asarray(ml_prob)
    # Setiap kondisi bernilai True jika perilaku mahasiswa berada di bawah
    threshold train.
    signal_map = {
        'Skor assessment rendah': result['assessment_score_mean'] <=
thresholds['assessment_score_mean'],
        'Partisipasi assessment rendah': result['assessment_count'] <=
thresholds['assessment_count'],
```

```

        'Total klik VLE rendah': result['vle_total_clicks'] <=
thresholds['vle_total_clicks'],
        'Hari aktif VLE rendah': result['vle_active_days'] <=
thresholds['vle_active_days']
    }
    result['risk_signal_count'] = sum(condition.astype(int) for condition in
signal_map.values())
    result['risk_reasons'] = [
        '; '.join(name for name, condition in signal_map.items() if
bool(condition.iloc[i])) or 'Tidak ada sinyal aturan'
        for i in range(len(result))
    ]
    # Aturan level risiko menggabungkan prediksi model dan jumlah sinyal
    perilaku.
    # Ini bukan clustering; ini grouping operasional dari hasil klasifikasi
    dan indikator awal.
    high = (result['predicted_atrisk'] == 1) & (result['risk_signal_count']
>= 2)
    medium = (result['predicted_atrisk'] == 1) | (result['risk_signal_count']
>= 2)
    result['knowledge_risk_level'] = np.select([high, medium], ['High Risk',
'Medium Risk'], default='Low Risk')

    # Rekomendasi dibuat dari jenis sinyal yang muncul pada tiap mahasiswa.
    def recommendation(row):
        reasons = row['risk_reasons']
        actions = []
        if 'VLE' in reasons: actions.append('pengingat dan monitoring akses
VLE')
        if 'assessment' in reasons: actions.append('pendampingan assessment')
        if row['risk_signal_count'] >= 3: actions.append('konseling atau
tindak lanjut dosen wali')
        return '; '.join(actions) if actions else 'monitoring rutin'
    result['recommended_action'] = result.apply(recommendation, axis=1)
    return result

# Terapkan knowledge layer pada data test agar hasilnya sejalan dengan
evaluasi hold-out.
test_output = dataset.iloc[test_idx].copy().reset_index(drop=True)
test_output = add_knowledge_layer(test_output, best_pred, best_prob,
thresholds)
print('Threshold aturan dari kuartil bawah data train:')
display(pd.Series(thresholds, name='threshold').to_frame().round(2))
display(test_output['knowledge_risk_level'].value_counts().to_frame('jumlah'))
display(test_output[['id_student', 'code_module', 'code_presentation',
'predicted_atrisk',
                        'probability_atrisk', 'risk_signal_count',
'knowledge_risk_level',
                        'risk_reasons', 'recommended_action']].head())

```

Threshold aturan dari kuartil bawah data train:

	threshold
assessment_score_mean	0.0
assessment_count	0.0
vle_total_clicks	47.0
vle_active_days	4.0

knowledge_risk_level									jumlah
Low Risk									2676
Medium Risk									1979
High Risk									1816
	id_stud ent	code module	code_p resentation	predict ed_atr isk	probab ility_atr isk	risk_si gnal_c ount	knowle dge_ris k_level	risk_re asons	recom mende d_actio n
0	11391	AAA	2013J	0	0.392	0	Low Risk	Tidak ada sinyal aturan	monitoring rutin
1	38053	AAA	2013J	0	0.188	0	Low Risk	Tidak ada sinyal aturan	monitoring rutin
2	52130	AAA	2013J	0	0.148	0	Low Risk	Tidak ada sinyal aturan	monitoring rutin
3	63400	AAA	2013J	0	0.164	0	Low Risk	Tidak ada sinyal aturan	monitoring rutin
4	74372	AAA	2013J	1	0.600	1	Medium Risk	Total klik VLE rendah	pengingat dan monitoring akses VLE

14. Evaluasi Alarm Intervensi

High Risk dan Medium Risk dipetakan menjadi alarm AtRisk, lalu metriknya dibandingkan dengan model machine learning final.

Penggabungan High Risk dan Medium Risk sebagai AtRisk sengaja diarahkan untuk meningkatkan cakupan deteksi. Konsekuensinya, precision, yaitu proporsi alarm yang benar-benar AtRisk, dapat turun dan antrean intervensi menjadi lebih besar. Hubungan saling tarik ini disebut trade-off, sehingga hasil tetap perlu diverifikasi manusia.

Tabel dan confusion matrix berikut menunjukkan perubahan recall dan precision setelah aturan diterapkan.

```
In [15]: # Untuk evaluasi biner, High Risk dan Medium Risk diperlakukan sebagai AtRisk.
# Pilihan ini menekankan recall, dengan konsekuensi precision dan beban intervensi perlu dipantau.
knowledge_pred = test_output['knowledge_risk_level'].isin(['High Risk', 'Medium Risk']).astype(int)
# Bandingkan metrik model ML murni dengan sistem setelah ditambah knowledge layer.
comparison = pd.DataFrame([
```



```

{'sistem': f'Model ML ({best_model_name})', **calculate_metrics(y_test,
best_pred, best_prob)},
{'sistem': 'Model + Knowledge Layer',
 'accuracy': accuracy_score(y_test, knowledge_pred),
 'precision_atrisk': precision_score(y_test, knowledge_pred,
zero_division=0),
 'recall_atrisk': recall_score(y_test, knowledge_pred, zero_division=0),
 'f1_atrisk': f1_score(y_test, knowledge_pred, zero_division=0),
 'roc_auc': np.nan}
]).set_index('sistem')
display(comparison.style.format('{:.4f}', na_rep='-'))
# Confusion matrix tambahan menunjukkan perubahan setelah aturan diterapkan.
print('Confusion matrix alarm intervensi:')
display(pd.DataFrame(confusion_matrix(y_test, knowledge_pred),
                      index=['Aktual Successful', 'Aktual AtRisk'],
                      columns=['Prediksi Successful', 'Prediksi AtRisk']))

```

	accuracy	precision_atrisk	recall_atrisk	f1_atrisk	roc_auc
sistem					
Model ML (Random Forest)	0.7594	0.8007	0.7213	0.7589	0.8396
Model + Knowledge Layer	0.7146	0.7043	0.7866	0.7432	-

Confusion matrix alarm intervensi:

	Prediksi Successful	Prediksi AtRisk
Aktual Successful	1951	1122
Aktual AtRisk	725	2673

15. Dashboard Monitoring Akademik

Dashboard menyatukan indikator model dan risiko untuk monitoring akademik. KPI (Key Performance Indicator) merangkum kondisi utama, seperti jumlah mahasiswa dalam antrian prioritas. Visualisasi mencakup distribusi level, risiko per module-presentation, probabilitas, sinyal dominan, perilaku per level, dan confusion matrix.

In [16]:

```

# Tetapkan urutan dan warna level risiko agar semua grafik konsisten.
level_order = ['High Risk', 'Medium Risk', 'Low Risk']
level_colors = {'High Risk': '#D62828', 'Medium Risk': '#F4A261', 'Low Risk': '#2A9D8F'}
level_counts =
test_output['knowledge_risk_level'].value_counts().reindex(level_order,
fill_value=0)
# Hitung persentase High/Medium Risk per module-presentation.
module_risk =
(test_output.assign(is_priority=test_output['knowledge_risk_level'].isin(['High
Risk', 'Medium Risk']))
    .groupby(['code_module', 'code_presentation'])
    ['is_priority'].mean()
    .sort_values(ascending=False).head(10).mul(100))
# Pecah alasan risiko menjadi indikator agar sinyal dominan bisa dihitung.
all_signals = (test_output['risk_reasons'].str.get_dummies(sep='; '))

```

```

        .drop(columns=['Tidak ada sinyal aturan'],
errors='ignore').sum().sort_values(ascending=False))
behavior_level = test_output.groupby('knowledge_risk_level')[
    ['vle_total_clicks', 'assessment_score_mean']].median().reindex(level_order)

# KPI dashboard merangkum jumlah mahasiswa dan antrean prioritas.
total_students = test_output['id_student'].nunique()
priority_count = test_output['knowledge_risk_level'].isin(['High Risk', 'Medium
Risk']).sum()
priority_pct = 100 * priority_count / len(test_output)

# Susun dashboard statis dari KPI, distribusi risiko, modul prioritas, dan
metrik evaluasi.
fig = plt.figure(figsize=(20, 18), constrained_layout=True)
grid = fig.add_gridspec(4, 3, height_ratios=[0.45, 1.5, 1.5, 1.5])
fig.suptitle('DASHBOARD EARLY WARNING OULAD – MINGGU KE-4', fontsize=22,
fontweight='bold')

kpis = [(f'{total_students:,}', 'Mahasiswa unik'), (f'{priority_count:,}',
'Prioritas intervensi'),
        (f'{priority_pct:.1f}%', 'Persentase prioritas')]
for i, (value, label) in enumerate(kpis):
    ax = fig.add_subplot(grid[0, i]); ax.axis('off')
    ax.text(0.5, 0.62, value, ha='center', va='center', fontsize=27,
fontweight='bold', color='#264653')
    ax.text(0.5, 0.18, label, ha='center', va='center', fontsize=12)
    ax.add_patch(plt.Rectangle((0.02, 0.02), 0.96, 0.96, fill=False,
edgecolor='#A8DADC', linewidth=2))

# Panel risiko: distribusi level dan module-presentation prioritas.
ax1 = fig.add_subplot(grid[1, 0])
ax1.pie(level_counts, labels=level_counts.index, autopct='%1.1f%%',
startangle=90,
        colors=[level_colors[x] for x in level_counts.index])
ax1.set_title('Distribusi Level Risiko')

ax2 = fig.add_subplot(grid[1, 1])
module_risk.sort_values().plot(kind='barh', ax=ax2, color='#E76F51')
ax2.set_title('10 Module-Presentation dengan Prioritas Tertinggi')
ax2.set_xlabel('High + Medium Risk (%)'); ax2.set_ylabel('Module-Presentation')

# Panel perilaku: probabilitas, sinyal dominan, dan median perilaku per level.
ax3 = fig.add_subplot(grid[2, 0])
sns.histplot(data=test_output, x='probability_atrisk',
hue='knowledge_risk_level',
        hue_order=level_order, palette=level_colors, bins=20, ax=ax3,
element='step')
ax3.set_title('Distribusi P(AtRisk) Menurut Level Risiko')

ax4 = fig.add_subplot(grid[2, 1])
all_signals.sort_values().plot(kind='barh', ax=ax4, color='#F4A261')
ax4.set_title('Sinyal Risiko Dominan'); ax4.set_xlabel('Jumlah mahasiswa')

ax5 = fig.add_subplot(grid[2, 2])
behavior_level.plot(kind='bar', ax=ax5, secondary_y='assessment_score_mean',
color=['#457B9D', '#E9C46A'])
ax5.set_title('Median Perilaku per Level Risiko'); ax5.tick_params(axis='x',
rotation=15)

# Panel evaluasi: confusion matrix dan perbandingan model dengan knowledge


```

```

layer.
ax6 = fig.add_subplot(grid[3, 0])
sns.heatmap(cm_best, annot=True, fmt='d', cmap='Blues', ax=ax6,
            xticklabels=['Successful', 'AtRisk'], yticklabels=['Successful',
            'AtRisk'])
ax6.set_title(f'Confusion Matrix {best_model_name}');
ax6.set_xlabel('Prediksi'); ax6.set_ylabel('Aktual')

ax7 = fig.add_subplot(grid[3, 1])
metric_plot = comparison[['precision_atrisk', 'recall_atrisk', 'f1_atrisk']]
metric_plot.plot(kind='bar', ax=ax7, color=['#457B9D', '#E76F51', '#2A9D8F'])
ax7.set_title('Model ML vs Alarm Intervensi (High atau Medium Risk)');
ax7.set_ylim(0, 1); ax7.tick_params(axis='x', rotation=0)
ax7.legend(loc='lower right')
plt.show()

```



16. Prioritas Intervensi dan Temuan Utama

Mahasiswa pada level High Risk dan Medium Risk diurutkan berdasarkan

`probability_atrisk` serta jumlah sinyal. Urutan ini membentuk antrian intervensi dan

menghasilkan temuan otomatis tentang module-presentation serta sinyal risiko dominan. Tabel

berikut menampilkan 20 prioritas teratas, probabilitas, alasan risiko, dan rekomendasi tindakan.

```
In [17]: # Daftar prioritas hanya mengambil mahasiswa dengan High Risk atau Medium Risk.
priority_table =
(test_output[test_output['knowledge_risk_level'].isin(['High Risk', 'Medium Risk'])]
.sort_values(['knowledge_risk_level', 'probability_atrisk',
'risk_signal_count'],
            ascending=[True, False, False])
[['id_student', 'code_module', 'code_presentation',
'probability_atrisk',
'knowledge_risk_level', 'risk_signal_count', 'risk_reasons',
'recommended_action']])

# Ambil konteks dan sinyal paling menonjol untuk insight BI otomatis.
top_context = module_risk.index[0]
top_signal = all_signals.index[0]
print('TEMUAN UTAMA UNTUK INTERVENSI AKADEMIK')
print(f'1. Prioritas tertinggi: module {top_context[0]} presentation {top_context[1]} '
      f'dengan {module_risk.iloc[0]:.1f}% kasus High/Medium Risk.')
print(f'2. Sinyal risiko paling dominan: {top_signal} ({int(all_signals.iloc[0]):,} kasus).')
print(f'3. Total antrean intervensi: {len(priority_table):,} student-module-presentation.')
print('4. Probabilitas dan alasan risiko membentuk urutan tindak lanjut.')
print('5. Daftar prioritas mendukung verifikasi dan intervensi akademik.')

# Tampilkan 20 prioritas teratas sebagai bahan tindak lanjut.
display(priority_table.head(20).style.format({'probability_atrisk': '{:.1%}'))
```

TEMUAN UTAMA UNTUK INTERVENSI AKADEMIK

1. Prioritas tertinggi: module GGG presentation 2014J dengan 100.0% kasus High/Medium Risk.
2. Sinyal risiko paling dominan: Skor assessment rendah (2,341 kasus).
3. Total antrean intervensi: 3,795 student-module-presentation.
4. Probabilitas dan alasan risiko membentuk urutan tindak lanjut.
5. Daftar prioritas mendukung verifikasi dan intervensi akademik.

	id_stude nt	code_m odule	code_pr esentati on	probabil ity_atris k	knowled ge_risk_ level	risk_sig nal_cou nt	risk_rea sons	recomm ended_a ction
116	323805	AAA	2014J	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
170	87604	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
171	88580	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
175	143854	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
201	323914	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin

	id_stude nt	code_m odule	code_pr esentati on	probabil ity_atris k	knowled ge_risk_ level	risk_sig nal_cou nt	risk_rea sons	recomm ended_a ction
							VLE rendah; Hari aktif VLE rendah	g atau tindak lanjut dosen wali
209	353918	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
211	357038	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
236	423317	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
267	488929	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
290	505123	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah;	penginga t dan monitorin g akses

	id_stude nt	code_m odule	code_pr esentati on	probabil ity_atris k	knowled ge_risk_ level	risk_sig nal_cou nt	risk_rea sons	recomm ended_a ction
							Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
302	512924	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
331	532142	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
366	541573	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali
374	542760	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut

	id_stude nt	code_m odule	code_pr esentati on	probabil ity_atris k	knowled ge_risk_ level	risk_sig nal_cou nt	risk_rea sons	recomm ended_a ction
							VLE rendah	dosen wali
376	543864	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
380	545514	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
387	546892	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
389	546941	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pangan assessm ent; konselin g atau tindak lanjut dosen wali
413	552056	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm	penginga t dan monitorin g akses VLE; pendam pangan

	id_student	code_module	code_presentation	probability_atrisk	knowledge_risk_level	risk_signal_count	risk_reasons	recommended_action
							ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	assessm ent; konselin g atau tindak lanjut dosen wali
438	557338	BBB	2013B	100.0%	High Risk	4	Skor assessm ent rendah; Partisipa si assessm ent rendah; Total klik VLE rendah; Hari aktif VLE rendah	penginga t dan monitorin g akses VLE; pendam pingan assessm ent; konselin g atau tindak lanjut dosen wali

17. Ekspor Artefak Analisis

Metrik model, evaluasi knowledge layer, dan daftar prioritas disimpan sebagai CSV untuk reproduksibilitas dan analisis lanjutan.

```
In [18]: # Folder output dibuat di runtime Colab.
OUTPUT_DIR = RUNTIME_DIR / 'oulad_dvbi_output'
OUTPUT_DIR.mkdir(exist_ok=True)
# Simpan metrik model, evaluasi knowledge layer, dan daftar prioritas ke
# CSV.
test_results.reset_index().to_csv(OUTPUT_DIR / 'model_evaluation.csv',
index=False)
comparison.reset_index().to_csv(OUTPUT_DIR /
'knowledge_layer_evaluation.csv', index=False)
priority_table.to_csv(OUTPUT_DIR / 'intervention_priority.csv', index=False)
# Tampilkan daftar artefak untuk reproduksibilitas analisis.
exported_files = pd.DataFrame({'Artefak': sorted(p.name for p in
OUTPUT_DIR.iterdir())})
print('Artefak analisis yang diekspor')
display(exported_files)
```

Artefak analisis yang diekspor

	Artefak
0	intervention_priority.csv
1	knowledge_layer_evaluation.csv
2	model_evaluation.csv

18. Kesimpulan dan keterbatasan

Kesimpulan: notebook berfokus pada predictive analytics dengan supervised binary classification untuk memprediksi **AtRisk** versus **Successful** pada skenario early warning minggu ke-4. Model dipilih berdasarkan recall **AtRisk**, lalu knowledge-based layer menambahkan level risiko, alasan, dan rekomendasi. Dashboard menerjemahkan keluaran tersebut menjadi monitoring dan prioritas intervensi.

Keterbatasan:

- Label berasal dari hasil akhir, sedangkan prediktor dibatasi sampai hari ke-28.
- Level **High Risk**, **Medium Risk**, dan **Low Risk** merupakan grouping operasional setelah klasifikasi.
- Threshold kuartil merupakan baseline berbasis data dan perlu divalidasi pakar akademik.
- Recall tinggi dapat meningkatkan false positive dan beban intervensi.
- Evaluasi fairness per kelompok demografis seperti gender, region, disability, dan tingkat pendidikan menjadi pengembangan penting untuk membaca sensitivitas model.
- Tuning hyperparameter, kalibrasi probabilitas, dan optimasi threshold klasifikasi menjadi pengembangan lanjutan setelah baseline model terbentuk.
- OULAD berasal dari konteks Open University di Inggris sehingga penerapan pada institusi lain memerlukan validasi ulang.
- Feature importance menunjukkan kontribusi prediktif dan ditafsirkan sebagai asosiasi dalam model.